

学校代码: 10491

研究生学号: 120040663

中国地质大学 硕士学位论文

演化 Kalman 滤波及其应用研究

硕士生: 龚文引

学科专业: 计算机应用技术

导师: 蔡之华 教授

二〇〇七年五月

A Dissertation Submitted to China University
of Geosciences for the Degree of Master of Engineering

**Research on Evolutionary Kalman Filter and Its
Application**

Master Candidate: Wenyin Gong

Major: Computer Application Technology

Supervisor: Prof. Zhihua Cai

China University of Geosciences

Wuhan 430074 P. R. China

研究生学位论文原创性声明

我以诚信声明：本人呈交的硕士学位论文是在导师蔡之华教授的指导下开展研究工作所取得的研究成果。文中关于“问题的综述性描述”、“带约束正交杂交算子的设计”、“差分演化算法的改进及应用”、“演化 Kalman 滤波算法原理的设计”、“基于郭涛算法、基本差分演化算法及改进差分演化算法的演化 Kalman 滤波器的实现与应用”、“在组合导航中的演化 Kalman 滤波器的设计原理”均系本人独立研究得出。所引用他人之思路、方法、观点、认识均已在参考文献中明确标注，所引用他人之数据、图件、资料均已征得所有者同意，并且也有明确标注，对论文的完成提供过帮助的有关人员也已在文中说明并致以谢意。

学位论文作者（签字）：

签字日期： 年 月 日

作者简介

龚文引，男(土家族)，1979 年生，湖南永顺人，硕士研究生，研究方向为演化数据挖掘、智能计算等。

课程及成绩：高级计算机体系结构：85；自然辩证法：87；科学社会主义：77；计算机应用数学：91；程序设计原理：81；算法设计与分析：85；硕士生英语：83.5（含专业英语）；计算机应用新专题：92；中国文化旅游：87；数据挖掘及知识发现：93；遗传算法：90；体育：92；科学方法论：通过；教学实践：通过。平均成绩：86.27, 总学分：32。

研究生期间主要项目经历：

- 1) 基于演化算法的优化器在工程优化中的应用.(“十五”项目“复杂工程应用平台设计”子课题)
- 2) 演化滤波及其应用.
- 3) 基因表达式编程算法研究.(湖北省自然科学基金项目, No: 2003ABA043)
- 4) 混合基因表达式并行算法研究.(湖北省人文社科开放基金项目, No: 2004B0011)

研究生期间所获得的奖励：

- 1) 2005 年 11 月 计算机学院科技论文报告会三等奖
- 2) 2006 年 05 月 中国地质大学(武汉)校级优秀共青团员
- 3) 2006 年 05 月 中国地质大学(武汉)校级优秀研究生标兵
- 4) 2006 年 12 月 西藏中凯矿业优秀学生奖学金
- 5) 2006 年 12 月 计算机学院科技论文报告会一等奖
- 6) 2006 年 12 月 中国地质大学(武汉)研究生科技论文报告会一等奖

研究生期间发表的主要学术论文(“△”表示相应的论文已公开发表)：

△[1] 龚文引，蔡之华. 基因表达式程序设计的原理与应用，微计算机信息，2005, 21(22): 169-170.

△[2] 龚文引，蔡之华，詹炜. 一种新的求解 0-1 背包问题的自适应算法，微型机与应用, 2005, 24(12): 63-66.

△[3] 龚文引，蔡之华，刘亚东. 基因表达式程序设计在复杂函数自动建模中的应用，系统仿真学报, 2006, 18(6): 1450-1454. (EI 网络版检索)

△[4] Wenyin Gong, Zhihua Cai, Xinwei Lu, *et al.* A New Mutation Operator Based on the T Probability Distribution in Evolutionary Programming, proceedings of the fifth IEEE International Conference on Cognitive Informatics (ICCI 2006). 2006.7: 675-679.

△[5] Wenyin Gong, Changmin Chen, and Zhihua Cai. Simple Diversity Rules and

- Improved Differential Evolution for Constrained Global Optimization, proceedings of the first International Conference on Bio-inspired Computing: Theory and Applications (BIC-TA 2006). 2006.9: 131-139.
- △[6] Wenyin Gong, Zhihua Cai, and Charles X. Ling. ODE: A Fast and Robust Differential Evolution Based on Orthogonal Design, AI 2006: Advances in Artificial Intelligence - 19th Australian Joint Conference on Artificial Intelligence (AJCAI 2006), LNAI 4304, Springer-Verlag. 2006.12: 709-718. **(ISTP 检索)**
- △[7] 詹炜, 戴光明, 龚文引. 求解函数优化问题的一种高效混合演化算法, 计算机工程与应用, 2006, 42(2): 70-72.
- △[8] J. Wang, L. Zhu, Z. H. Cai, W. Y. Gong, *et al*, Training RBF Networks with an Extended Kalman Filter Optimized Using Fuzzy Logic, proceeding of 4th International Conference on Intelligence Information Processing (IIP2006). 2006.9: 317 - 326. **(ISTP 检索)**
- △[9] Zhihua Cai, Wenyin Gong, and Yongqin Huang. A Novel Differential Evolution Algorithm based on ϵ -domination and Orthogonal Design Method for Multiobjective Optimization, proceedings of the 4th International Conference on Evolutionary Multi-Criterion Optimization (EMO'07), LNCS 4403, 2007.3.
- [10] 龚文引, 刘小波, 蔡之华. 一种基于正交设计的快速差分演化算法及其应用研究, 小型微型计算机系统. (已录用)

演化 Kalman 滤波及其应用研究

硕士生：龚文引

导师：蔡之华 教授

摘 要

演化算法是一类模拟生物进化过程与机制求解问题的自组织、自适应、自学习的人工智能技术，具有稳健性、通用性、思想简单、易于实现、应用效果明显等优点，基于种群的搜索机制使其适合大规模并行。演化算法在不同的科学领域得到了广泛的应用，其中演化最优化是演化计算的应用方向之一。

Kalman 滤波是一套由计算机实现的实时递推算法，它所处理的对象是随机信号，利用系统噪声和观测噪声的统计特性，以系统观测量作为滤波器的输入，以所要估计值（系统的状态或参数）作为滤波器的输出，滤波器的输入与输出之间是由时间更新和观测更新算法联系在一起的，根据系统方程和观测方程估计出所有需要处理的信号。它不但可以对平稳的一维的随机过程进行估计，也可以对非平稳的、多维随机过程进行估计，因此适用范围比较广泛。Kalman 滤波理论被用于随机最优控制问题、故障诊断等应用领域，其中组合导航系统中的设计是其成功应用的一个主要方面。

本文首先简介了演化算法和 Kalman 滤波的背景知识，然后，提出了一种新的基于正交设计的差分演化算法，以增强算法的鲁棒性和加快算法收敛速度，更利于应用于演化 Kalman 滤波的设计中。新算法在保持传统差分演化算法的简单、有效等特性的同时，还具有以下一些特点：1) 引入一种基于正交设计的杂交算子，并结合约束统计优生法来产生最好子个体；2) 采用决策变量分块策略，以减少正交实验次数，加快算法收敛速度；3) 提出一种简单的多样性规则，以处理约束条件；4) 提出基于非凸理论的多父体混合自适应杂交变异算子，以增强算法的非凸搜索能力和自适应能力；5) 简化基本差分演化算法的缩放因子，尽量减少算法的控制参数，方便工程人员的使用。为了验证改进算法的性能，本文通过一些函数优化实例对算法进行了测试，并与其他演化算法的结果相比较，其结果表明，新算法在解的精度、稳定性和收敛性上表现出很好的性能。在验证了改进算法的性能并指出了函数优化与演化 Kalman 滤波的联系之后，在第四章，本文提出了演化 Kalman 滤波的设计思路，并把郭涛算法、基本差分演化算法和改进的差分演化算法应用于演化 Kalman 滤波器设计中，由此形成三种演化 Kalman 滤波器（DEKF, GTKF 和 ODEKF），通过把这三种演化 Kalman 滤波器应用到一个具体实例中进行算法性能测试。实验结果表明，在经验值估计较为准确的情况下，三个演化 Kalman 滤波器（DEKF, GTKF 和 ODEKF）均能在一定程度上改进传统 Kalman 滤波器的性能，其中 ODEKF 的改进性能最好，平均改进效率在[8.1211%,12.529%]之间。当经验值估计不准确的时候，三个演化 Kalman 滤波器

（DEKF, GTKF 和 ODEKF）的性能要明显优于传统 Kalman 滤波器的性能，其中 GTKF 和 ODEKF 的改进性能要优于 DEKF，GTKF 和 ODEKF 的平均改进效率分别在

[7.3918%,30.912%]和[7.3677%,34.082%]之间,便于以后在工程中的应用。同时,对演化 Kalman 滤波在 INS/GPS 组合导航系统的应用进行了初探。

本文的主要创新之处在于: 1) 提出一种新的基于正交设计的差分演化算法; 2) 指出了演化函数优化与演化 Kalman 滤波之间的关系; 3) 提出了演化 Kalman 滤波的理论框架,并把三个不同的演化算法应用到演化 Kalman 滤波中测试其性能; 4) 对基于演化 Kalman 滤波的 INS/GPS 组合导航系统的原理进行了初探,提出了相应的原理框架。

本文的主要章节安排如下:

第一章主要介绍了演化算法与优化计算的一些背景知识,并介绍了演化算法的一些特性;同时,简要介绍了 Kalman 滤波理论的背景及其在组合导航中的应用。

第二章主要介绍 Kalman 滤波器的理论基础,基本方程及其一些改进的 Kalman 滤波器。同时,介绍 Kalman 在组合导航中的一些应用。

第三章重点介绍了差分演化算法的基本原理,同时把正交设计的思想引入到差分演化算法中,对差分演化算法进行改进,并把改进差分演化算法应用到函数优化问题的求解中。

第四章指出了演化 Kalman 滤波与演化函数优化之间的联系,并提出演化 Kalman 滤波器的基本设计思路;给出本文中应用到的演化 Kalman 滤波器的详细设计方法;把郭涛算法、基本差分演化算法和改进的差分演化算法应用于演化 Kalman 滤波器中,并把此演化 Kalman 滤波器应用到一个具体实例中,测试算法的性能。同时,对演化 Kalman 滤波在 INS/GPS 组合导航系统的应用进行了初探。

第五章为本文总结部分,对本文的工作进行了总结,并对未来工作提出了一些设想。

关键词: 演化算法; Kalman 滤波; 差分演化算法; 正交设计; 组合导航

RESEARCH ON EVOLUTIONARY KALMAN FILTER AND ITS APPLICATION

Master Candidate: Wenyin Gong Supervisor: Prof. Zhihua Cai

ABSTRACT

Evolutionary algorithms (EAs) are search methods that take their inspiration from natural selection and survival of the fittest in the biological world, which have many characteristics such as self-organization, self-adaptive, robustness, universality, the thought simply, easy to implement, the effective and efficient application and so on. It suits massively parallel because it is a generic population-based metaheuristic optimization algorithm. Evolutionary algorithm has been widely applied in the different scientific domain and engineering optimization, in which evolutionary optimization is one direction.

The Kalman filter is a real-time recursion algorithm, which realizes by the computer. It processes the object with the random signal. And it uses the statistical property of the system noise and the observation noise to process the signal. Kalman filter applies the system observation as the input of the filter and the estimation (system state or parameter) as the output. Between the input and the output of the filter it processes the signal according to the system equation and the observation equation. Not only it may carry on the process to the steady uni-dimensional stochastic process, also it can estimate the non-steady, the multi-dimensional stochastic process, therefore its application is very widespread. The Kalman filter is widely used in stochastic optimum control, breakdown diagnosis and so on, in which INS/GPS navigation system design is a success application of it.

In this thesis, firstly, I briefly introduce the background of the Evolutionary Algorithm (EA) and Kalman filter. Secondly, a novel Differential Evolution algorithm (DE) based on the orthogonal design method is proposed in order to make DE more robust and faster. Moreover, ODE can make the Evolutionary Kalman Filter (EvoKF) more effective and efficient. The ODE combines the conventional DE (CDE), which is simple and efficient, with the orthogonal design, which can exploit the optimum offspring. The ODE has some features. 1) It uses a robust crossover based on orthogonal design and an optimal offspring is generated with the constrained statistical optimal method. 2) To decrease the number of the orthogonal design and make the

algorithm converge faster, decision variable fraction strategy is applied here. 3) It uses simple diversity rules to handle the constraints and maintain the diversity of the population; 4) A multi-parent hybrid adaptive-crossover-mutation operator based on the non-convex theory is proposed, which can enhance the non-convex search ability. 5) The ODE simplifies the scaling factor F of the CDE, which can reduce the parameters of the algorithm and make it easy to use for engineers. We execute the proposed algorithm to solve 12 benchmark functions with low or high dimensions and very large numbers of local minima. Through comparison with some state-of-the-art evolutionary algorithms, the experimental results demonstrate that the performance of the ODE outperforms other evolutionary algorithms in terms of the quality of the final solution and the stability; and its computational cost (measured by the average number of fitness function evaluations) is lower than the cost required by the other techniques compared. Thirdly, in Chapter 4, the basic principle of the evolutionary Kalman filter (EvoKF) is proposed. To estimate the performance of the EvoKF, we employ the Guo's algorithm (GT) and the conventional Differential Evolution (CDE) algorithm in the EvoKF after I point out the relationship between function optimization and EvoKF. Simulations indicate that the three proposed EvoKF (DEKF, GTKF, and ODEKF) can improve the performance compared on the conventional Kalman filter both in exact estimation value and in non-exact estimation value. Meanwhile, I propose the principle of the EvoKF to apply in INS/GPS elementarily.

The main innovations of this thesis are: 1) A novel DE algorithm based on the orthogonal design method is proposed. 2) I point out the relationship between function optimization and EvoKF. 3) I propose the basic principle of EvoKF and test its performance using three algorithms. And 4) I propose the principle of the EvoKF to apply in INS/GPS.

The main chapters are as follows:

Chapter 1, we mainly introduced the background knowledge of the evolutionary algorithm and the optimization computation, and introduced some characteristics of the evolutionary algorithm. At the same time, we briefly introduced the background of the Kalman filter theory and its application in INS/GPS navigation system.

Chapter 2, the theory of the Kalman filter, its basic equations and some improved Kalman filters were introduced. Meanwhile, we introduced the application of the Kalman filter in INS/GPS navigation system.

Chapter 3, we introduced the basic theory of the conventional Differential Evolution. Also, we proposed a novel Differential Evolution based on the orthogonal design method (ODE) to make Differential Evolution faster and more robust. To test the performance of ODE, we tested it on a number of benchmark function optimization problems.

Chapter 4, we proposed the principle of the evolutionary Kalman filter (EvoKF) and pointed out the relationship between EvoKF and the evolutionary function optimization. Also we introduced the design method of the EvoKF in detail, including how to design the fitness function, how to encode and decode the individual, and how to deal with the constraints. Thereafter, we use the GT, CDE and ODE in the EvoKF with a simulation example to test the performance of the EvoKF. Meanwhile, we proposed the evolutionary INS/GPS navigation

system based on the EvoKF proposed above.

Chapter 5, we summarized the main work of this thesis and described our future work.

Key Words: Evolutionary algorithm; Kalman filter; Differential Evolution; orthogonal design; INS/GPS

目 录

第一章 绪论.....	1
§1.1 引言.....	1
§1.2 演化算法与优化计算.....	2
1.2.1 优化计算.....	2
1.2.2 演化算法.....	2
§1.3 Kalman 滤波器在组合导航中的应用.....	4
§1.4 本文工作及章节安排.....	5
1.4.1 本文主要工作.....	5
1.4.2 主要章节安排.....	5
第二章 Kalman 滤波及其在组合导航系统中的应用.....	6
§ 2.1 Kalman 滤波的理论基础.....	6
§ 2.2 随机线性离散系统的 Kalman 滤波.....	8
2.2.1 随机线性离散系统的 Kalman 滤波方程.....	9
2.2.2 随机线性离散系统的 Kalman 滤波特点.....	11
2.2.3 Kalman 滤波的改进.....	12
§ 2.3 基于 Kalman 滤波组合导航系统.....	13
第三章 差分演化算法的改进及其应用.....	15
§ 3.1 基本差分演化算法.....	15
§ 3.2 改进差分演化算法.....	17
3.2.1 函数优化问题描述.....	18
3.2.2 相关工作.....	18
3.2.3 正交设计.....	19
3.2.4 正交差分演化算法 ODE.....	20
§ 3.3 ODE 在函数优化中的应用.....	24
3.3.1 实验环境及参数设置.....	24
3.3.2 测试函数.....	24
3.3.3 实验结果.....	25
3.3.4 结果分析.....	25
§ 3.4 小节.....	28
第四章 演化 Kalman 滤波器的设计及其应用研究.....	29
§ 4.1 相关工作.....	29
§ 4.2 演化函数优化与演化 Kalman 滤波器的关系.....	31
§ 4.3 演化 Kalman 滤波器的设计.....	32
4.3.1 演化 Kalman 滤波器的原理.....	32

4.2.2 基于 ODE 算法的演化 Kalman 滤波	36
§ 4.4 演化 Kalman 滤波算法(EvoKF)的应用	37
4.4.1 EvoKF 的基本应用.....	37
4.4.2 EvoKF 在组合导航中的应用初探.....	47
§ 4.5 小结.....	49
第五章 全文总结	50
致谢.....	52
参考文献.....	53

第一章 绪论

§ 1.1 引言

目前科学技术已进入多学科相互交叉、相互渗透、相互影响的时代。这一点在计算机科学领域表现的更为突出。一方面, 计算机科学的迅速发展从根本上改变了人类的生活、学习和工作的方式, 使人类文明进入了一个崭新的时代; 另一方面, 随着人类生存空间的扩大和认识世界改造世界范围的拓展, 人们又对计算机科学提出了新的要求和期望。而所有的期望之中, 对计算机的计算速度和具有智能的要求也许是最迫切和最基本的。近些年来, 一些新的研究方向如人工神经网络 (ANN)^[1,2]、细胞自动机 (CA)^[3]和演化计算 (Evolutionary Computation, EC)^[4]等, 由于它们通过模拟某一自然现象或过程以使问题得到解决, 具有适于高度并行及自组织、自适应、自学习等特征, 因而正受到越来越多的关注。

大自然是人类解决各种问题是获得灵感的源泉。自然界中生物进化论揭示了生物长期自然选择的进化发展规律, 认为生物进化主要有三个原因: 遗传、变异和选择。演化计算正是基于这种思想而发展起来的一种通用的问题求解方法。它采用简单的编码来表示各种复杂的结构, 并通过对一组编码表示进行简单的遗传操作和优胜劣汰的自然选择来知道学习和确定搜索的方向。在赋予演化计算自组织、自适应、自学习等特征的同时, 优胜劣汰自然选择和简单的遗传操作使演化计算具有不受其搜索空间限制性条件的约束及不需要其他辅助信息的特点。这些崭新的特点是演化计算不仅能获得较高的效率而且具有简单、易于操作和通用的特点, 而这些特征正是演化计算越来越受到人们青睐的主要原因之一。

将演化计算应用于新型惯性组合导航系统的研制中, 实现智能化的组合导航系统, 提高系统对空间环境的鲁棒性。惯性导航系统由于其高自主性、信息全面, 实时性强等诸多优点, 使其成为制导、导航与控制系统 (GNC) 的关键子系统, 其性能的优劣是影响 GNC 系统性能的关键要素之一, 成为 GNC 系统研制时所关注的焦点。随着民用航天技术的发展, 系统要求惯性导航系统具有高精度、高可靠性等特点。采用以惯性导航系统为主, 其它信息为辅助的组合导航系统成为提高导航系统精度的有效途径。但由于惯性器件性能在地面环境试验中获得的参数很难更精确地反应天上动态环境下的参数, 引入了事先不可测知的误差, 使滤波能力受限、控制精度受限; 卫星导航也存在此类问题。因此, 有必要在组合导航系统设计中引入新的基于演化建模的、具有自学习能力的智能化自适应滤波技术, 以提高传统滤波算法的精度。本文的研究正是基于此目标而进行的。

§ 1.2 演化算法与优化计算

1.2.1 优化计算

优化是指在给定的约束条件下，求出使目标函数（组）最大或最小的变量组合问题。从理论上讲，任何确知的约束条件及目标函数的优化问题都存在一组实质解，工程中我们不但关心这组解是否存在，而且关心求解所需要的运算时间。最优解问题可以根据所需要的求解时间分为几类。假定问题的“大小”是 N ，如果存在一个算法，求解问题的时间与 N 只成多项式（或更低）的关系，则说它是多项式时间复杂度，属于 P 类问题。与 P 类问题相反的称为 NP 完全问题，其求解时间最少也是 N 的指数关系。介于 NP 与 P 类问题之间的称为 NP 类问题。已经证明，如果能找到一个确定的算法以多项式时间求解一个 NP 完全问题，那么所有其它 NP 问题都能以多项式时间求解，在这种算法下， P 、 NP 、 NP 完全问题则都属于相同的类。

优化计算一直是一个很热的研究领域，其理论及方法的起源可以追溯到微积分诞生的年代。特别是随着军事、航天等发展的迫切需要，发展更为迅速。一些传统的基于迭代原理的数值算法，如单纯性法、共轭方向法、罚函数法等得以产生并在工业生产、经济等领域得到了广泛的应用。

然而，传统的数值算法存在以下的缺点：

- 一般对目标函数都有较强的限制要求，如连续、可微、单峰等。
- 大多数优化方法都是根据目标函数的局部展开性质来确定下一步搜索的方向，这与求函数的整体最优解的目标有一定的抵触，因此，这些方法也容易陷入函数的局部最优解。
- 在实现算法之前，要进行大量的准备工作，如求函数的一阶和二阶导数、某些矩阵的逆、初始点为可行解等。在目标函数较为复杂的情况下，这一工作是很困难的，有事甚至是不可能的。
- 算法的结果一般与初始值的选取有较大的关系，不同的初值可能导致不同的结果。初始值的选取较大地依赖于优化者对问题背景的人之及所掌握的知识。
- 算法缺乏简单性和通用性。针对一个问题，优化方法的使用者学要有相当的知识去判断使用哪一种方法较为适合。这一困难是使优化方法得到更为广泛应用的重要障碍之一。
- 对某些约束问题（特别是等式约束很多的问题）较难处理。

1.2.2 演化算法

近年来，很多学者利用演化算法来求解优化问题，取得了很大的成功，并已经引起了人们的普遍关注。越来越多的人加入到演化优化的研究之中，并对演化算法作了许多改进，使

得更适合优化问题。目前,演化算法已广泛应用于无约束函数优化、约束函数优化、组合优化、多目标优化等多种优化问题的求解中。

演化计算(Evolutionary Computation, 简记为 EC)求解问题的基本思想相当简单:由问题的候选解组成一个种群,然后通过随机变化和选择等算子进行演化。其中随机变化提供了发现新解的机制,选择则确定保持哪些解作为下一步搜索的基础。

由于 EC 算法固有的特点,确定了具有以下几方面的优异特性:

- (1) 以优化变量的遗传编码为运算、搜索对象。传统的优化算法往往直接对优化变量进行优化计算,但 EC 不是如此而是以优化变量的某种形式的遗传编码为运算对象,它们可以是字符串、图或抽象公式。这种对优化变量的编码处理方式使得在优化计算过程中可以借鉴生物学中染色体和基因等概念,可以模仿自然界中生物进化机制与遗传变异原理,也使得我们可以方便地应用遗传、演化等操作算子。另外,对一些非数值概念或很难用数值概念而只能用代码的优化问题(这类问题称为非数值优化问题),EC 的这种处理方式显示了其独特的优越性。
- (2) 只应用“适应值”信息,而不需应用目标函数的具体值及其它辅助信息。传统优化算法不仅依赖于目标函数的具体值,而且也需要应用目标函数的导数值等其它一些辅助信息来确定搜索方向。而 EC 通常仅使用经过目标函数变换得到的适应度值。由于个体的适应度可以不依赖于目标函数具体值(例如只要知道排序关系),这使得 EC 不仅可以方便地应用于那些有目标函数,但很难求导数,或导数不存在的优化问题(特别如组合优化与非光滑优化问题),而且,更重要地,可应用于那些目标函数无明确表达,或有表达但不可精确估值的优化问题。
- (3) 非单点操作,使用群体搜索策略。传统优化算法往往是从解空间中的一个初始点开始进行单点迭代(从而形成解空间中的一条轨迹)。单个点所提供的搜索信息毕竟不多,因而其搜索效率不高,有时甚至使搜索过程陷于局部极值而停滞不前。而 EC 的搜索是由多个个体所组成的初始种群起始的种群空间中的迭代过程(从而形成个体空间中的多条轨迹),其搜索过程的每一步利用了种群中各个体所提供的信息(即群体信息)。这些信息可以避免一些不必要搜索点或区域,从而既提高了搜索效力,也避免了陷入局部极小值陷阱。另外,EC 的群体搜索机制使其具有自然的并行性,从而适宜于在当代或未来以分布、并行为特征的智能计算机上发挥潜能。
- (4) 使用随机搜索机制。很多传统优化算法使用的是确定性的搜索方法,一个搜索点到另一个搜索点的转移有确定的转移关系,这种确定性使得算法的搜索具有定向性,从而很难达到问题的全局最优解,而且数值稳定性不好。EC 在计算的各个步骤使用随机转移规则,因而是一类导向的随机搜索技术(directed random search)。特别是,其选择、繁殖(杂交、变异等)等操作都是以一种概率的方式进行的,采用的是“软”,选择与“让步策略”,它能以一定概率接受不一定好的个体,从而大大提高了算法跳出局部极小值陷阱的能力。另外,随机搜索机制的一个自然优点是相应算法的健壮性(robustness) EC 自然也具有这一特征。这样,概括起来说,EC 具有通用、并行、稳健、简单与全局优化能力强等突出优点。

上述优点决定了 EC 的适用范围应该是复杂、困难的全局优化问题。

§ 1.3 Kalman 滤波器在组合导航中的应用

Kalman 滤波是卡尔曼(R. E. Kalman)于 1960 年提出的从与被提取信号有关的观测量中通过算法估计出所需信号的一种滤波算法^[5]。他把状态空间的概念引入到随机估计理论中,把信号过程视为白噪声作用下的一个线性系统的输出,用状态方程来描述这种输入—输出之间的关系,估计过程中利用系统状态方程、观测方程和白噪声激励(系统噪声和观测噪声)的统计特性形成滤波算法,由于所有的信息都是时域内的量,因此不但可以对平稳的一维的随机过程进行估计,也可以对非平稳的、多维随机过程进行估计。这就完全避免了 Wiener 滤波在频域内设计时遇到的限制,使用范围比较广泛。

实际上, Kalman 滤波是一套由计算机实现的实时递推算法,它所处理的对象是随机信号,利用系统噪声和观测噪声的统计特性,以系统的观测值作为滤波器的输入,以所要估计值(系统的状态或参数)作为滤波器的输出,滤波器的输入与输出之间是由时间更新和观测更新算法联系在一起的,根据系统方程和观测方程推导出所有需要处理的信号^[6]。所以,本文中所谈的 Kalman 滤波与常规滤波的涵义与方程完全不同,实质上是一种最优估计方法。

继 1960 年, R. E. Kalman 提出了离散系统的 Kalman 滤波之后, 次年, 他与布西(R. S. Bucy)合作, 把这一滤波方法推广到连续时间系统中去^[7], 从而形成 Kalman 滤波估计理论。这种滤波方法采用了与 Wiener 滤波相同的估计准则, 二者的基本原理是一致的。但是, Kalman 滤波是一种时域滤波方法, 采用状态空间方法描述系统, 算法采用递推形式, 数据存储量小, 不仅可以处理平稳随机过程, 也可以处理多维和非平稳随机过程。

正是由于 Kalman 滤波具有以上一些其他滤波方法所不具备的有点, Kalman 滤波理论一提出, 立即应用到实际工程中。阿波罗登月计划和 C-5A 飞机导航系统的设计是最早应用中最成功的实例。随着电子计算机的迅速发展和广泛应用, Kalman 滤波在工程实践中, 特别实在航空空间技术中迅速得到应用。目前, Kalman 滤波理论作为一种最重要最优估计理论被广泛应用于各种领域, 如惯性导航(INS)、制导系统、全球定位系统(GPS)、目标跟踪、通信于信号过程、金融、电机等。进一步, Kalman 滤波理论被应用于最优控制问题、故障诊断等应用领域, GPS/INS 其中组合导航系统的设计是最成功的一个最主要的方面。

传统的 Kalman 滤波要求已知系统的精确数学模型和噪声统计。对于一个实际系统, 往往存在着模型不确定性和干扰信号统计特性不完全已知, 这些不确定因素使得传统的 Kalman 滤波算法失去最优性, 估计精度大大降低, 严重时会引起滤波发散。近些年来, 人们将鲁棒控制思想引入到滤波中, 形成了鲁棒滤波理论。其中较有代表性的鲁棒滤波算法是 H^∞ 鲁棒滤波算法^[6]为了抑制滤波器发散, 出现了很多自适应 Kalman 滤波算法, 解决含有未知模型参数和噪声统计系统或含有未建模动态系统的滤波问题。自适应 Kalman 滤波在计算过程中, 一方面利用观测不断地修正预测值, 同时也对未知的或不确切知道的系统模型参数和噪声统计参数进行估计和修正。通常用噪声统计或模型参数估值器伴随 Kalman 滤波器实现自适应滤波^[8]。自适应 Kalman 滤波主要包括多模型自适应估计算法和新息自适应估计^[8]两类。这些方法在不同程度上利用新息过程(序列)来识别和纠正滤波异常, 这是因为新息反

映了理论预报值与实际检测值之间的差别,反映了理论偏离实际的程度^[9]。对于新息的利用程度不同,将在不同程度上改善估计精度。随着人工智能技术的发展,专家系统、模糊理论、神经网络和遗传算法也被用来改善 Kalman 滤波效果。

§ 1.4 本文工作及章节安排

本文的研究工作是在国防科学技术工业委员会“十一五”民用航天项目“航天器控制自主演化计算及其应用研究”(项目编号:C5220061318)的资助下完成。

1.4.1 本文主要工作

本文的工作主要包括以下几个方面:

- (1) 简要分析 Kalman 滤波的基本理论以及对已有 Kalman 滤波的一些改进。
- (2) 分析差分演化算法(Differential Evolution, DE)的搜索原理;对差分演化算法进行改进,并将改进的差分演化算法应用于函数优化问题的求解中。
- (3) 指出了演化 Kalman 滤波与演化函数优化之间的联系,并提出演化 Kalman 滤波器的基本设计思路;给出本文中应用到的演化 Kalman 滤波器的详细设计方法;把郭涛算法、基本差分演化算法和改进的差分演化算法应用于演化 Kalman 滤波器中,并把此演化 Kalman 滤波器应用到一个具体实例中,测试算法的性能。
- (4) 对演化 Kalman 滤波在 INS/GPS 组合导航系统的应用进行了初探。

1.4.2 主要章节安排

- (1) 第一章为绪论部分,主要介绍了演化算法与优化计算的一些背景知识,并介绍了演化算法的一些特性;同时,简要介绍了 Kalman 滤波理论的背景及其在组合导航中的应用。
- (2) 第二章主要介绍 Kalman 滤波器的理论基础,基本方程及其一些改进的 Kalman 滤波器。同时,介绍 Kalman 在组合导航中的一些应用。
- (3) 第三章重点介绍了差分演化算法的基本原理,同时把正交设计的思想引入到差分演化算法中,对差分演化算法进行了改进,并把改进的差分演化算法应用到函数优化问题的求解中。
- (4) 第四章提出演化 Kalman 滤波器的基本设计思路,指出演化 Kalman 滤波与演化函数优化之间的联系;给出本文中应用到的演化 Kalman 滤波器的详细设计方法;把郭涛算法、基本差分演化算法和改进的差分演化算法应用于演化 Kalman 滤波器中,并把此演化 Kalman 滤波器应用到一个具体实例中,测试算法的性能。同时,对演化 Kalman 滤波在 INS/GPS 组合导航系统的应用进行了初探。
- (5) 第五章为本文总结部分,对本文的工作进行了总结,并对未来工作提出了一些设想。

第二章 Kalman 滤波及其在组合导航系统中的应用

§ 2.1 Kalman 滤波的理论基础

在工程系统随机控制和信息处理问题中，通常所得到的观测信号中不仅包含所需的信号，而且还包含有随机观测噪声和干扰信号。通过对一系列带有观测噪声和干扰信号的实际观测数据的处理，从中得到所需要的各种参量的估计值，这就是估计问题。在工程实践中，经常遇到的估计问题有两类：（1）系统的结构参数部分或全部未知、有待确定；（2）实施最优控制需要随时了解系统的状态，而由于种种限制，系统中的一部分或全部状态变量不能直接测得。这就形成了估计的两类问题——参数估计和状态估计^[6]。

一般估计问题都是由估计验前信息、估计约束条件和估计准则三部分构成。假设

- (1) X 是 n 维未知状态或参数， \hat{X} 为其估计值。
- (2) Z 为与 X 有关的 m 维观测向量，它与 X 的关系可以表示为

$$Z = f(X, V) \quad (2.1)$$
- (3) V 为 m 维观测噪声，它的统计特性部分或全部已知。

则一般地，估计问题可叙述为：给定观测向量 Z 和观测噪声向量 V 的全部或部分统计规律，根据选定的准则和约束条件(2.1)，确定一个函数 $H(Z)$ ，使得它成为（在选定准则下） X 的最优估计，即

$$\hat{X} = H(Z) \quad (2.2)$$

为了衡量估计的好坏，必须要有一个估计准则。在应用中，我们总是希望估计出来的参数或状态越接近实际值越好，即得到状态或参数的最优估计。很显然，估计准则可能是各式各样的，最优估计不是唯一的，它随着准则的不同而不同。因此，在估计时，要恰当选择衡量估计的准则。

如前所述，估计准则以某种方式度量了估计的精确度，它体现了估计是否最优的含义。准则应该用函数来表达，估计中称这个函数为指标函数或损失函数。一般来说，损失函数是根据验前信息选定的，而估计式则是通过损失函数的极小化或极大化导出的。不同的损失函数，导致不同的估计方法。原则上，任何具有一定性质的函数都可用作损失函数^[6]。然而，从估计理论的应用实践看，可行的损失函数只有少数几种。目前估计中常用的三种准则是直接误差准则、误差函数矩准则和直接概率准则。

直接误差准则,是指以某种形式的误差(比如估计误差 $\tilde{X} = X - \hat{X}$ 或对 Z 的拟合误差 $\tilde{Z} = Z - \hat{Z}$, \hat{Z} 是 \hat{X} 的函数)为自变量的函数作为损失函数的准则。在这类准则中,损失函数是误差的凸函数,估计式是通过损失函数的极小化导出的,而与观测噪声的统计特性无关。因此,这类准则特别适用于观测噪声统计规律未知的情况。最小二乘估计及其各种推广形式都是以误差平方和最小作为估计准则的。

误差函数矩准则,是指以直接误差函数矩作为损失函数的准则。特别地,我们可把损失函数 \tilde{X} 选作直接误差函数,以其均值为零和方差最小为准则。在这类准则中,要求观测噪声的有关矩是已知的,显然它比直接误差准则要求更多的信息,因而有望具有更高的精度。最小方差估计、线性最小方差估计等都是属于这类准则的估计。

直接概率准则,这类准则的损失函数是以某种形式误差的概率密度函数构成,有事也用熵函数构成。估计式由损失函数的极值条件导出。由于这类准则与概率密度函数有关,这就要求有关的概率密度函数存在,而且要知道它的形式。另外,除少数情况外,在这类准则下,估计的导出比较苦难,因此,这类准则的应用是极有限的。极大似然估计和极大验后估计就是这类准则的直接应用。

选取不同的估计准则,就有不同的估计方法,估计方法与估计准则是紧密相关的。相应于上述三类估计准则,常用的估计方法有最小二乘估计、线性最小方差估计、最小方差估计、极大似然估计和极大验后估计。

在估计问题中,常考虑如下随机线性离散系统模型

$$X_k = \Phi_{k,k-1} X_{k-1} + \Gamma_{k,k-1} W_{k-1}, \forall k \geq 0 \quad (2.3a)$$

$$Z_k = H_k X_k + V_k, \forall k \geq 0 \quad (2.3b)$$

式中 X_k 是系统的 n 维状态向量, Z_k 是系统的 m 维观测向量, W_k 是系统的 p 维随机干扰向量, V_k 是系统的 m 维观测噪声向量, $\Phi_{k,k-1}$ 是系统的 $n \times n$ 维状态转移矩阵, $\Gamma_{k,k-1}$ 是 $n \times p$ 维干扰输入矩阵, H_k 是 $m \times n$ 维观测矩阵。在以后的讨论中,省略条件 $\forall k \geq 0$ 。

根据状态向量和观测向量在时间上存在的不同对应关系,我们可以把估计问题分为滤波、预测和平滑,以式(1.3)所描述的随机线性离散系统为例,设 $\hat{X}_{k,j}$ 表示根据 j 时刻和 j 以前时刻的观测值,对 k 时刻状态 X_k 做出的某种估计,则按照 k 和 j 的不同对应关系,分别叙述如下:

- (1) 当 $k = j$ 时, 对 $\hat{X}_{k,j}$ 的估计称为滤波, 即依据过去直至现在的观测量来估计现在的状态。相应地, 称 $\hat{X}_{k,k}$ 为 X_k 的最优滤波估计值, 简记为 \hat{X}_k 。这类估计主要用于随机系统的实时控制。
- (2) 当 $k > j$ 时, 对 $\hat{X}_{k,j}$ 的估计成为预测或外推, 即依据过去直至现在的观测量来预测未来的状态, 并把 $\hat{X}_{k,j}$ 称为 X_k 的最优预测估计值。这类估计主要用于系统未来状态的预测和实时控制。
- (3) 当 $k < j$ 时, 对 $\hat{X}_{k,j}$ 的估计成为平滑或内插, 即依据过去直至现在的观测量去估计过去的历史状态, 并称 $\hat{X}_{k,j}$ 成为 X_k 的最优平滑估计值。这类估计广泛应用于通过分析实验或试验数据, 对系统进行评估。

若把 X_k 换成 X_t , $\hat{X}_{k,j}$ 换成 $\hat{X}(t, t_1)$, 则上述分类对于连续时间系统同样使用。换句话说, 线性系统的状态估计都可以分为上述三类。

在预测、滤波和平滑三类状态估计问题中, 预测是滤波的基础, 滤波是平滑的基础。在本文的研究中主要讨论滤波问题。

Kalman 滤波是卡尔曼(R. E. Kalman)于 1960 年提出的从与被提取信号有关的观测量中通过算法估计出所需信号的一种滤波算法^[5]。他把状态空间的概念引入到随机估计理论中, 把信号过程视为白噪声作用下的一个线性系统的输出, 用状态方程来描述这种输入—输出之间的关系, 估计过程中利用系统状态方程、观测方程和白噪声激励(系统噪声和观测噪声)的统计特性形成滤波算法, 由于所有的信息都是时域内的量, 因此不但可以对平稳的一维的随机过程进行估计, 也可以对非平稳的、多维随机过程进行估计。这就完全避免了 Wiener 滤波在频域内设计时遇到的限制, 使用范围比较广泛。

继 1960 年, R. E. Kalman 提出了离散系统的 Kalman 滤波之后, 次年, 他与布西(R. S. Bucy)合作, 把这一滤波方法推广到连续时间系统中去^[7], 从而形成 Kalman 滤波估计理论。这种滤波方法采用了与 Wiener 滤波相同的估计准则, 二者的基本原理是一致的。但是, Kalman 滤波是一种时域滤波方法, 采用状态空间方法描述系统, 算法采用递推形式, 数据存储量小, 不仅可以处理平稳随机过程, 也可以处理多维和非平稳随机过程。

§ 2.2 随机线性离散系统的 Kalman 滤波

2.2.1 随机线性离散系统的 Kalman 滤波方程

设随机线性离散系统的方程（本文的研究不考虑控制作用）为

$$X_k = \Phi_{k,k-1} X_{k-1} + \Gamma_{k,k-1} W_{k-1} \quad (2.4a)$$

$$Z_k = H_k X_k + V_k \quad (2.4b)$$

式中 X_k 是系统的 n 维状态向量, Z_k 是系统的 m 维观测向量, W_k 是系统的 p 维随机干扰向量, V_k 是系统的 m 维观测噪声向量, $\Phi_{k,k-1}$ 是系统的 $n \times n$ 维状态转移矩阵, $\Gamma_{k,k-1}$ 是 $n \times p$ 维干扰输入矩阵, H_k 是 $m \times n$ 维观测矩阵。

关于系统过程噪声和观测噪声的统计特性, 作如下假定

$$\begin{cases} E[W_k] = 0, & E[W_k W_j^T] = Q_k \delta_{kj} \\ E[V_k] = 0, & E[V_k V_j^T] = R_k \delta_{kj} \\ E[W_k V_j^T] = 0 \end{cases} \quad (2.5)$$

其中 Q_k 是系统过程噪声 W_k 的 $p \times p$ 维对称非负定方差矩阵, R_k 是系统观测噪声 V_k 的 $m \times m$ 维对称正定方差矩阵, 而 δ_{kj} 是 Kronecker- δ 函数, 其定义为

$$\delta_{kj} = \begin{cases} 0 & k \neq j \\ 1 & k = j \end{cases} \quad (2.6)$$

下面直接给出随机线性离散系统基本 Kalman 滤波方程。本文省略了其推导过程, 有兴趣的读者可以参考文献^[6, 11, 12]。

如果被估计状态 X_k 对 X_k 的观测量 Z_k 满足式 (2.4) 的约束, 系统过程噪声 W_k 和观测噪声 V_k 满足式 (2.6) 的假设, 系统过程噪声方差矩阵 Q_k 非负定, 系统观测噪声方差矩阵 R_k

正定, k 时刻的观测为 Z_k , 则 X_k 的估计 \hat{X}_k 可按下述方程求解:

状态一步预测

$$\hat{X}_{k,k-1} = \Phi_{k,k-1} \hat{X}_{k-1} \quad (2.7a)$$

状态估计

$$\hat{X}_k = \hat{X}_{k,k-1} + K_k [Z_k - H_k \hat{X}_{k,k-1}] \quad (2.7b)$$

滤波增益矩阵

$$K_k = P_{k,k-1} H_k^T [H_k P_{k,k-1} H_k^T + R_k]^{-1} \quad (2.7c)$$

一步预测误差方差矩阵

$$P_{k,k-1} = \Phi_{k,k-1} P_{k-1} \Phi_{k,k-1}^T + \Gamma_{k,k-1} Q_{k-1} \Gamma_{k,k-1}^T \quad (2.7d)$$

估计误差方差矩阵

$$P_k = [I - K_k H_k] P_{k,k-1} [I - K_k H_k]^{-1} + K_k R_k K_k^T \quad (2.7e)$$

其中，式（2.7c）可以进一步写成

$$K_k = P_k H_k^T R_k^{-1} \quad (2.7c1)$$

式（2.7e）可以进一步写成

$$P_k = [I - K_k H_k] P_{k,k-1} \quad (2.7e1)$$

或

$$P_k^{-1} = P_{k,k-1}^{-1} + H_k^T R_k^{-1} H_k \quad (2.7e2)$$

式（2.7）即为随机线性离散系统 Kalman 滤波基本方程。只要给定初值 \hat{X}_0 和 P_0 ，根据 k 时刻的观测值 Z_k ，就可以递推计算得 k 时刻的状态估计 $\hat{X}_k (k=1,2,\dots)$ 。

在一个滤波周期内，从卡尔曼滤波在使用系统信息和观测信息的先后次序来看，Kalman 滤波具有两个明显的信息更新过程：时间更新过程和观测更新过程^[10]。式（2.7a）说明了根据 $k-1$ 时刻的状态估计预测 k 时刻窗台的方法，式（2.7d）对这种预测的质量优劣做了定量描述。该两式的计算中仅使用了与系统的动态特性有关的信息，如状态一步转移矩阵、噪声输入矩阵、过程噪声方差矩阵。从时间的推移过程来看，该两式将时间从 $k-1$ 推进至 k 时刻，描述了 Kalman 滤波的时间更新过程。式（2.7）的其余公式用来计算对时间更新值的修正量，该修正量由时间更新的质量优劣（ $P_{k,k-1}$ ）、观测信息的质量优劣（ R_k ）、观测与状态的关系（ H_k ）以及具体的观测信息 Z_k 所确定，所有这些方程围绕一个目的，即正确、合理地利用观测 Z_k ，所以这一过程描述了 Kalman 滤波的观测更新过程。这两个过程如图 2.1 所示




图 2.1 Kalman 滤波更新过程

式 (2.7a) 和式 (2.7b) 又称为 Kalman 滤波器方程, 由此两式可得到 Kalman 滤波器方框图^[6], 如图 2.2 所示。在图 2.2 中, 滤波器的输入是系统状态的观测值, 输出是系统状态的估计值。




图 2.2 随机线性离散系统 Kalman 滤波器结构图

2.2.2 随机线性离散系统的 Kalman 滤波特点

从式 (2.7) 我们可以得到 Kalman 滤波算法的如下一些特点:

- (1) 由于 Kalman 滤波算法将被估计的信号看作在白噪声作用下的一个随机线性系统的输出, 并且其输入输出关系是由状态方程和输出方程在时间域给出的, 因此, 这种滤波方法不仅适用于平稳序列的滤波, 而且特别适用于非平稳或平稳马尔可夫序列或高斯-马尔可夫序列的滤波, 因此其应用范围是十分广泛的。
- (2) 由于 Kalman 滤波的基本方程是时间域内的递推形式, 其计算过程是一个不断地“预测-修正”过程, 在求解时不要求存储大量数据, 并且一旦观测到了新

的数据, 随时可以算出新的滤波值, 因此, 这种滤波方法非常便于实时处理, 同时也方便计算机的实现。

- (3) 由于滤波器的增益矩阵与观测无关, 因此它可预先离线算出, 从而可以减少实时在线计算量; 在求滤波器增益矩阵 K_k 时, 要求一个矩阵的逆, 即要计算

$(H_k P_{k,k-1} H_k^T + R_k)^{-1}$, 它的阶数只取决于观测方程的维数 m , 而 m 通常是很小的, 这样, 上面的求逆运算是比较方便的; 另外, 在求解滤波器增益的过程中, 随时可以算得滤波器的精度指标 P_k , 其对角线上的元就是滤波误差向量各分量的方差。

- (4) 增益矩阵 K_k 与初始方差矩阵 P_0 , 系统噪声方差矩阵 Q_{k-1} 以及观测噪声方差矩阵 R_k 之间具有如下关系:

- 由 Kalman 滤波的基本方程(2.7c)、(2.7d)可以看出: P_0, Q_{k-1} 和 $R_k (k=1, 2, \dots)$ 同乘一个相同的标量时, K_k 值不变。
- 由滤波的基本方程 (2.7c) 可见, 当 R_k 增大时, K_k 就变小, 这在直观上是很容易理解的, 因为如果观测噪声增大, 那么滤波增益就应取小一些 (因为这时的新信息里的误差就变大), 以减弱观测噪声对滤波值的影响。
- 如果 P_0 变小, Q_{k-1} 变小, 或者都变小, 则由滤波的基本方程 (2.7d) 可以看出, 这是 $P_{k,k-1}$ 变小, 而从滤波的基本方程 (2.7e) 可以看出, 这是的 P_k 也变小, 从而 K_k 变小。这也是很自然的。因为 P_0 变小, 表示初始估计较好, Q_{k-1} 变小, 表示系统噪声变小, 于是增益矩阵也应小些以便给予较小的修正。

综上所述, 可以简单地说, 增益矩阵 K_k 和 Q_{k-1} 成正比, 而与 R_k 成反比。

2.2.3 Kalman 滤波的改进

在很多实际系统中, 系统噪声方差矩阵 Q_k 和观测噪声方差矩阵 R_k 事先是不知道的, 有

时, 状态转移矩阵 Φ_k 或量测矩阵 H_k 也不能确切知道。如果根据不确切的模型进行滤波就可能会引起滤波发散^[6]。有时即使开始模型选择的比较符合实际, 但在运行过程中, 模型存在摄动, 也就是 Q_k 、 R_k 或 Φ_k 、 H_k 起了变化。在这种情况下, 首先要估计变化了的 Q_k 或 R_k , 进而调整滤波增益矩阵 K_k 。

自适应滤波是一种具有抑制滤波器发散作用的滤波方法, 它在滤波计算过程中, 一方面利用观测不断地修正预测值, 同时也对未知的或不确切知道的系统模型参数和噪声统计参数进行估计和修正。自适应滤波的方法有很多, 如贝叶斯法、极大似然法、相关法与协方差匹配法。其中最基本也是最重要的是相关法又可分为输出相关法和新息相关法。自适应滤波是目前 Kalman 滤波的一个研究方向。

在全球定位系统 GPS 和惯性导航系统 INS 中, 目前应用的较多的是 Sage-Husa 自适应滤波算法。GPS/INS 组合导航系统作为目前世界上应用最为广泛的导航方法之一, 其二者具有较强的非相似性和互补性, 将二者结合起来, 可以取长补短, 充分发挥各自的优势, 同时可以克服 GPS 容易受地形地物遮挡而导致定位中断和 INS 定位误差随时间而积累的缺陷。在 GPS/INS 组合导航系统中, 由于系统本身系统噪声和观测噪声统计特性的准确描述带来困难, 如果采用预建噪声模型的常规 Kalman 滤波器, 在实际引用中不能保证收敛性和稳定性^[6]。因此, 采用一种基于滤波收敛性判据的 Sage-Husa 自适应滤波和强跟踪 Kalman 滤波的改进自适应滤波算法就可以有效抑制滤波发散, 具有较大范围的自适应能力。

§ 2.3 基于 Kalman 滤波组合导航系统

导航是指将运载体从起点引导到目的地的技术或方法^[11]。导航系统测量并解算除运载体的瞬时运动状态和位置, 提供给驾驶员或自动驾驶仪实现对运载体的正确操纵或控制。随着科学技术的发展, 可供利用的导航信息越来越多, 导航系统的种类也越来越多。以航空导航为例, 目前可供装备的机载导航系统有惯性导航系统、GPS 导航系统、多普勒导航系统、罗兰 C 导航系统等等, 这些导航系统各有特色, 优缺点并存。比如, 惯性导航(以下简称惯导)系统的优点是: 不需要任何外来信息也不向外辐射任何信息, 可在任何介质和任何环境条件下实现导航, 且能输出飞机的位置、速度、方位和姿态等多种导航参数, 系统的频带宽, 能跟踪运载体的任何机动运动, 导航输出数据平稳, 短期稳定性好。但惯导系统具有固有的缺点: 导航精度随时间而发散, 即长期稳定性差。GPS 导航系统导航精度高, 在美国国防部加入 SA(Selective Availability)误差后, 使用 C/A 码信号的水平和垂直定位精度仍分别可达到 100m 和 157m (2σ), 且不随时间发散, 这种高精度和长稳定性是惯导系统望尘莫及的。但是 GPS 导航系统也有其致命弱点: 频带窄, 当运载体作较高机动运动时, 接收机的码环和载波环极易失锁而丢失信号, 从而完全丧失导航能力; 完全依赖于 GPS 卫星发射的导航信息, 受制于人, 且容易人为干扰和电子欺骗。其余导航系统也各有优缺点。

各种导航系统单独使用时是很难满足导航性能要求的, 提高导航系统整体性能的有效途径是采用组合导航技术, 即用两种或两种以上的非相似导航系统对同一导航信息作测量并解算以形成量测量, 从这些量测量中计算出各种导航系统的误差并校正之。采用组合导航的系统称为组合导航系统, 参与组合的各导航系统称为子系统。

实现组合导航有两种基本方法:

- (1) 回路反馈法, 即采用经典的回路控制方法, 抑制系统误差, 并使各种子系统间实现性能互补。
- (2) 最优估计法, 即采用卡尔曼滤波或维纳滤波, 从概率统计最优的角度估计出系统误差并消除之。两种方法都使各子系统内的信息互相渗透, 有机结合, 七大性能互补的功效。但由于各子系统的误差源和量测误差都是随机的, 所以第二种方法远优于第一种方法。这机组合导航系统时一般都采用卡尔曼滤波 (Kalman Filter, KF)。由于惯导(INS)和 GPS 在性能上正好形成互补, 所以采用该两种系统作为组合导航设计中的子系统时世界上公认的最佳方案, 如图 2.3 所示。




图 2.3 INS/GPS 组合导航系统原理图

组合导航系统一般具有以下 3 种功能:

- (1) 协合超越功能。组合导航系统能充分利用各子系统的导航信息, 形成单个子系统不具备的功能合精度。
- (2) 互补功能。由于组合导航系统综合利用了各子系统的信息, 所以各子系统能取长补短, 扩大使用范围。
- (3) 余度功能。各子系统感测同一信息源, 使测量值冗余, 提高整个系统的可靠性。

Kalman 滤波算法通常被用来实现 INS/GPS 组合导航, 将速度、位置、失准角和惯性仪表的误差作为状态变量, 通过最优估计的方法将其估计出来, 从而消除惯导误差。系统的可观测性决定了状态估计的速度和精度。

由此可见, 采用卡尔曼滤波理论的 INS/GPS 组合导航系统具有优越的性能, 目前, 也是各国在航天领域种使用的最为广泛的导航技术, 比如把卡尔曼滤波理论应用于惯导系统初始对准中以及应用基本滤波理论设计组合导航系统等。

第三章 差分演化算法的改进及其应用

§ 3.1 基本差分演化算法

演化算法是一种基于群体的启发式搜索算法^[13],它利用群体中的个体在解空间中进行搜索,具有自适应、自学习、自组织和隐并行性等特点。在演化过程中,群体中的个体通过遗传算子产生新个体,保持群体的多样性,对新的空间进行搜索,以得到问题的最优解。目前,演化算法已出现了很多分支,其中最主要的有遗传算法(GAs)、进化规划(EP)、演化策略(ES)和遗传程序设计(GP)等。演化算法已在很多领域取得了广泛的应用,如约束或无约束函数优化^[14, 15]、多目标优化^[16]、组合优化^[17]等。同时,演化算法还在实际工程优化领域^[18, 19]等得到了广泛而成功的应用。

差分演化算法^[20](Differential Evolution, DE)是一种快速的演化算法,它采用实数编码,并利用个体间的差分信息来指导新产生个体的搜索。该算法在首届 IEEE 演化计算竞赛中表现突出,并获得广泛的应用,与其他演化算法相比,具有结构简单、容易使用、快速和鲁棒性等特点、为了求解具有不同特征的函数,K. Price 和 R. Storn 设计了 10 中不同的差分演化策略,以供使用者选择^[21]。

基本差分演化算法(Conventional Differential Evolution, CDE)实际上采用了一种多父体重组算子来产生新个体,而且是一种稳态演化算法。差分演化算法的选择算子简单且容易实现,每次产生的新个体仅与其父个体进行比较,如果子个体优于父个体,则子个体替换父个体;反之,则保留父个体,丢弃子个体。CDE 的多父体重组算子是由一个变异算子和杂交算子组合而成,其变异算子为(由于在文献[21]中提出了 10 种策略,此处仅以本文研究中要用到的 DE/rand/1/exp 作为例子)

$$X'_i = X_{r1} + F(X_{r2} - X_{r3}) \quad (3.1)$$

其中, X'_i 表示群体中第 i 个个体通过变异算子式 (3.1) 产生的个体, X_{r1} , X_{r2} 和 X_{r3} 为群体中随机选择出的三个个体($r1 \neq r2 \neq r3 \neq i$), F 为缩放因子,一般在 $[0, 2]$ 之间取值。式 (3.1) 的搜索可以用图 3.1 表示如下:




图 3.1 基本差分演化算法(CDE)的 DE/rand/1/exp 的二维空间搜索示意图

在 CDE 中, 最后产生的子个体并不仅仅是通过式 (3.1) 产生的, 在通过变异算子式 (3.1) 产生个体 X_i' 后, 再通过 DE 的杂交算子形成最后的子个体 Y_i , 其公式如下

$$Y_i^j = \begin{cases} X_i'^j & p < CR \parallel j = m \\ X_i^j & \text{else} \end{cases} \quad (3.2)$$

其中, $j=1,2,\dots,n$, n 为自变量的个数, m 为 $\{1,2,\dots,n\}$ 中一个随机数, X_i^j 表示第 i 个父个体 X_i 的第 j 维分量, CR 为 DE 算法的杂交概率, p 为 $[0, 1]$ 之间的随机数。从式 (3.2) 可以看出, DE 算法的子个体 Y_i 是由其父个体 X_i 和变异子个体 X_i' 共同组成, 也所以称由式 (3.1) 和式 (3.2) 组成的算子为混合杂交变异算子。式 (3.2) 的过程可由图 3.2 来表示:




图 3.2 DE 算法的杂交算子示意图

CDE 算法的基本流程与遗传算法的类似：首先随机产生初始化群体；判断终止条件是否满足，如果不满足则继续；利用重组算子产生新个体，并与父个体进行比较；通过选择算子来产生新的群体；继续执行算法，直到满足终止条件退出算法。采用 DE/rand/1/exp 的 CDE 算法流程图如图 3.3 所示：




图 3.3 采用 DE/rand/1/exp 的 CDE 算法流程图

§ 3.2 改进差分演化算法

由于差分演化算法具有结构简单、容易使用、快速和鲁棒性等优点，使得它一提出就受到了许多学者和工程人员的重视，对其做了很多研究并提出了许多改进的方法。

尽管 CDE 具有很多优点, 但是, 它在求解全局最优优化问题时会出现在演化后期收敛较慢的问题, 特别是在处理带约束的全局优化问题时, 如果全局最优解在可行区域和不可行区域的边界, 那么会出现局部收敛或者很难求解出全局最优解。此外, CDE 对缩放因子 F 的选取是比较敏感的, 需要根据不同的问题选择不同的 F 值, 这就对工程应用带来了一定的麻烦, 有时要通过很多次实验才能得到较优的值。为此, 许多学者提出了多种改进方法, 以提高 DE 算法的通用性和进一步加快其收敛速度。

为了提高那 CDE 算法的性能, 加速其收敛速度, 在本文的研究中对其进行了改进, 提出一种新的混合自适应交叉变异算子以增强算法的全局搜索能力和非凸区域搜索; 同时, 为了使算法在演化中能够产生很好的个体, 采用正交杂交算子和直观统计方法产生子个体, 并与决策变量分块策略相结合, 以减少正交实验次数, 加快算法的收敛速度。该算法简称为 ODE (Orthogonal Differential Evolution)。为了使算法更为简单易用, ODE 算法简化了缩放因子 F 的选取, 采用在 $(0,1]$ 区间取一致随机数。同时, 为了增强算法对带约束的函数优化问题的处理, 提出一种新的多样性规则, 以保持群体的多样性, 处理约束函数。

3.2.1 函数优化问题描述

不失一般性, 以最小化函数优化问题为例, 可以描述为:

$$\text{Minimize } f(X), \quad X = (x_1, x_2, \dots, x_N) \in R^N \quad (3.3)$$

满足:

$$\begin{cases} g_i(X) \leq 0, & i=1,2,\dots,p \\ h_j(X) = 0, & j=1,2,\dots,q \end{cases} \quad (3.4)$$

其中 $X \in S \cap \Gamma$, $S \subseteq R^N$ 称为搜索空间, Γ 是可行区域, $f(X)$ 称为目标函数, X 是一个 N 维决策向量, $X = [x_1, x_2, \dots, x_N]^T$, 通常每个自变量 x_i 满足一定的约束条件

$$l_i \leq x_i \leq u_i, \quad i=1,2,\dots,N \quad (3.5)$$

p 是不等式约束函数个数, q 是等数约束函数个数, 约束可以是线性的, 也可以是非线性的。

对于不等式约束函数, 如果满足 $g_i(X) = 0$, 则称这个约束函数在点 X 为活动的。所以, 所有等式约束函数在整个可行区域都是活动的。在式 (3.4) 中, 当 $p=0, q=0$ 时, 则问题 (3.3) 就转变成无约束函数优化问题。

3.2.2 相关工作

文献[14, 22]提出一种基于量化方法的正交遗传算法来求解函数优化问题。算法中提出采用正交设计的方法产生初始群体, 并采用正交杂交算子产生新个体, 取得了很好的效果。算法在收敛速度和解的精度上都有了很大的改进。最近有的学者把这种思想应用到多目标问题的求解中^[25], 取得了很好的效果。

文献[23]采用正交设计的方法来选择遗传算法的参数, 通过对参数的有效均匀选择, 以避免参数设置的盲目性, 在求解函数优化问题中取得了较好的效果。文献[24]在此基础上, 利用正交设计对解空间进行划分, 通过重复使用不同的正交表来获得全局最优解, 并且还证

明了正交遗传算法的收敛性。但是,作者指出,算法在搜索时,有时找不出合适的正交表,从而导致算法性能的降低。

在求解带约束的全局最优化问题时,一般都采用罚函数法来处理约束函数,即采用一个罚因子对约束函数进行惩罚,然后把惩罚项加入到目标函数中,使问题转换成不带约束的全局优化问题。尽管这一方法得到了广泛的使用,但是其缺点是对罚因子的设置和调节是很困难的^[27,28],过大或过小的惩罚都有可能使算法不能得到问题的全局最优解。文献[29]中详细分析了罚因子对带约束函数优化问题求解的影响,并针对一般罚函数法的缺点提出了随机排序策略,取得了较好的效果。但是,在算法中引入了随机排序概率控制参数 P_f ,而对 P_f 的选取是很困难的,需要随问题的不同而进行调整,通常要经过多次尝试才能选出合适的值。

文献[30]提出了一种基于锦标赛的选择策略来处理可行个体和不可行个体。在文献[30]的方法中,可行个体总是优于不可行个体;两个可行个体中具有较小适应值的个体优于较大适应值的个体(在最小化问题中);两个不可行个体中具有较小违约值的个体优于较大违约值的个体。这个方法的缺点是不能保持群体的多样性,特别是最优解在可行区域和不可行区域边界时很难找出全局最优值。

文献[31]把差分演化算法与文献[30]的个体选择策略相结合来求解带约束的全局优化问题,由于没有采用保持群体多样性的机制,因此算法容易陷入局部最优解。

文献[32]提出一种基于多父体杂交的群体爬山演化算法,并通过一种能够保持群体多样性的比较策略来判断个体的优劣,在求解带不等式约束的全局最优化中取得了较好的效果。但该算法只用于求解带不等式约束的最优化问题,且算法的函数评价次数也比较多,这在实际工程优化中是很难得以广泛使用。

文献[33]采用同态映射方法把搜索空间映射到可行空间内以便对约束进行处理。这种方法主要是把原始问题转换成一个简单的问题来求解。但该算法的性能不是很好,对许多函数算法都不能得到最优解。

文献[34]提出的 ASCHEA 算法主要采用自适应罚函数法来处理约束函数,同时引入了基于可行解的分离选择策略。但是,该算法在对带约束的多峰函数进行优化时结果比较差。

3.2.3 正交设计

在工农业和科学研究中,经常要考虑多个因素对产品的影响。如果对每个因素不同水平的相互搭配安排全面实验的话,常常是很困难的甚至不可能实现。正交设计法^[26]是一种通过较少数次试验,就能找到最好或较好的试验条件。因此,它被广泛地用于寻优。在寻优时,先确定影响指标的因素和水平,再选择适当的正交表,即可按正交表安排试验,最后,分析试验的结果和发现较好的水平。

正交表具有以下一些特点。

- 1) 正交表中任意两列横向各数码搭配所出现的次数相同,从而保证了实验的典型性;
- 2) 任一系列中不同水平个数相同,这使得不同水平的实验次数相同;
- 3) 没有完全重复的实验,任意两个结果间不能直接比较;
- 4) 正交表中任意两列互换,仍是正交表;

5) 如果把一些列从正交表中取走, 剩余的表仍是正交表.

3.2.4 正交差分演化算法 ODE

3.2.4.1 正交杂交算子

(1) 正交表的设计

为了设计尽可能小的正交表, 在 ODE 中采用 2 水平正交表 $L_{2^J}(2^{2^J-1})$, 并设 $R=2^J$ 表示正交表的行数, 即实验组合数, $C=2^J-1$ 表示正交表的列数, 则所设计的正交表应满足下列关系:

$$\begin{aligned} \text{Minimize: } R &= 2^J \\ \text{S.t.: } C &= 2^J - 1 \geq N \end{aligned} \quad (3.6)$$

其中, N 表示自变量的维数. 在算法中应找出合适的 J 使公式(4)满足. 选择了合适的正交表之后, 算法采用文献[14]提到的正交表产生方法先生成正交表的基本列, 然后再生成非基本列来产生正交表. 为了方便起见, 所产生的正交表用 $L(R, C)$ 表示, 其中 $L(i, j)$ 表示第 j 个因素的第 i 个组合.

(2) 正交子群体的产生

在产生了合适的正交表之后, 则可对随机选择出的两个父个体 $X_1 = (x_{11}, x_{12}, \dots, x_{1N})$ 和 $X_2 = (x_{21}, x_{22}, \dots, x_{2N})$ 进行 2 水平正交杂交, 生成正交子群体, 其算法如下:

算法 1: 正交子群体 $O(R, N)$ 的产生

```

for i=1 to R
  for j=1 to N
    k = L(i, j)
    if k == 1 then
      O(i, j) = x1j
    End if
    if k == 2 then
      O(i, j) = x2j
    End if
  End
End

```

注: 由于所产生的正交表的列数 $C \geq N$, 所以, 当 $C > N$ 时, 在算法 1 中会舍去后面的 $C - N$ 列. 这是因为正交表的性质 5 保证了余下的表仍是正交表, 从而不会因去掉一些列失去了表的正交性.

(3) 带约束的直观统计优生法

为了能够从所产生的正交子群体中选择一个较好的个体作为子个体, 文献[14]主要采用按适应值的大小来选择子个体, 但是, 从正交表的性质 3 可知, 任意两个结果间不能直接比较. 所以为了能够通过正交设计产生一个最优的个体, 算法在传统直观统计法^[26]的基础上提

出一种带约束的直观统计优生法生成子个体, 以满足对约束条件的处理. 这与文献[35]采用的 Taguchi 方法和文献[36]采用的统计优生法类似, 但这里在直观法的基础上加入了约束处理条件以保证群体的多样性. 计算第 j 个因素第 k 个水平的目标函数统计值 $E(j,k)$ 和约束函数统计值 $CE(j,k)$ 的公式如下:

$$\begin{cases} E(j,k) = \sum_{L(i,j)=k} X_i \cdot f \\ CE(j,k) = \sum_{L(i,j)=k} X_i \cdot cf \end{cases} \quad (3.7)$$

其中 $X_i \cdot f$ 表示正交子群体中第 i 个组合的目标函数适应值, $X_i \cdot cf$ 是正交子群体中第 i 个组合的所有约束函数适应值之和. 这样对每个因素, 采用算法 2 产生一个最优子个体. 对于 ODE 算法中 2 水平正交杂交直观统计法如算法 2 所示.

算法 2: 约束统计优生法产生子个体

```

for j=1 to N      // 计算各统计值
  for i=1 to R
    k = L(i,j)
    if k == 1 then
      E(j,1) += Xi·f
      CE(j,1) += Xi·cf
    End if
    if k == 2 then
      E(j,2) += Xi·f
      CE(j,2) += Xi·cf
    End if
  End
End

for j=1 to N      // 约束统计优生法产生子个体
  if CE(j,1) < CE(j,2) then
    xj' = x1j
  else if CE(j,1) > CE(j,2) then
    xj' = x2j
  else if (CE(j,1) = CE(j,2)) ∧ (E(j,1) < E(j,2)) then
    xj' = x1j
  else
    xj' = x2j
  End if
End

```

3.2.4.2 决策向量分块策略

当自变量维数比较高时, 所设计的正交表的行数也会相应增大, 如 $N=30$ 时, $R=32$; $N=100$ 时 $R=128$. 在利用算法 2 产生一个子个体时就会有因评价次数过多, 而使算法的效率

降低, 为此, ODE 算法采用了决策向量分块策略, 把自变量分成一些块(分块可以是相等的, 也可以不相等, 为了计算简单此处采用等间隔分块), 以减少因数个数. 如把 30 维自变量分成两块, 这样产生的正交表 $R=4$ 即可满足设计要求. 具体实现的时候只需对算法 1 作一些小的改动, 此处不再列出.

3.2.4.3 简单多样性规则

为了保持群体的多样性, 在处理带约束函数优化时, 提出了如下规则来比较两个个体的优劣. 公式(3.8)计算个体的目标适应度值; 公式(3.9)计算个体的所有约束函数的值之和; 公式(3.10)比较两个个体的优劣.

$$X.f = f(X) \quad (3.8)$$

$$X.cf = \sum_{i=1}^q \max\{0, g_i(X)\} + \sum_{j=1}^p \max\{0, |h_j(X)| - \eta\} \quad (3.9)$$

$$Better(X_1, X_2) = \begin{cases} X_1.cf < X_2.cf, & 1 \\ X_1.cf > X_2.cf, & 0 \\ (X_1.cf = X_2.cf) \cap (X_1.f < X_2.f), & 1 \\ (X_1.cf = X_2.cf) \cap (X_1.f = X_2.f), & 2 \\ (X_1.cf = X_2.cf) \cap (X_1.f > X_2.f), & 0 \end{cases} \quad (3.10)$$

其中, $|h_j(X)| - \eta$ 表示把等式约束通过减去一个很小的正数(即等式容差)转换成不等式约束来求解. 在公式(3.10)中, 如果返回值为 1 表示个体 X_1 优于 X_2 , 在演化中接受个体 X_1 ; 如果返回值为 0 表示个体 X_1 劣于 X_2 , 在演化中接受个体 X_2 ; 如果返回值为 2 表示个体 X_1 与 X_2 具有相同的性能, 在演化中以相同概率接受这两个个体. 这样可以保证具有一些不可行个体也在群体中, 从而减轻了选择压力和保持了群体的多样性. 显然, 式 (3.10) 也适合于无约束的函数优化问题, 此时对所有的个体 $X.cf = 0$.

3.2.4.4 混合自适应杂交变异算子

为了增强算法的非凸搜索能力, 在 ODE 算法中设计了多父体非凸杂交算子, 如公式(3.11)所示.

$$P_1 = \sum_{i=1}^P a_i * X_i \quad (3.11)$$

其中, $a_i \in [-0.5, 1.5]$ 是一个随机数, 并且 $\sum_{i=1}^P a_i = 1$, P 表示所选择的父个体个数. a_i 从区间 $[-0.5, 1.5]$ 中取随机数可以增强算法的非凸区域的搜索能力. 图 3.4 表示 a_i 从区间 $[-0.5, 1.5]$ 中取随机数和 a_i 从区间 $[0.0, 1.0]$ 中取随机数时由三个父个体(1, 1), (6, 2), (5, 7)随机产生 100 个子个体的搜索示意图. 从图中可以看出, 当 a_i 从区间 $[-0.5, 1.5]$ 中取随机数时所产生的个体并不局限于父个体所形成的子空间中, 在子空间外也有很多子个体, 从而实现了非凸区间搜索的能力, 这对一些具有非凸特性的问题是很有效的.

ODE 算法通过公式(3.11)和 DE/rand/1/exp 策略分别产生一个个体, 然后选择较好的个体作为子个体, 与父个体进行比较, 若子个体优于父个体则替换父个体; 否则舍弃子个体. 具

体如算法 3 所示.

算法 3: 混合自适应杂交变异算子

for $i=1$ to M

 随机选择 P 个不同的个体;

 利用公式(3.11)产生一个子个体 P_1 ;

 随机选择 3 个个体 $X_{r_1}, X_{r_2}, X_{r_3}$, 满足 $r_1 \neq r_2 \neq r_3 \neq i$;

 通过 DE/rand/1/exp 产生一个子个体 P_2 ;

 比较 P_1, P_2 的大小, 较优的个体作为子个体 X' ;

 if $f(X') < f(X_i)$ then

$X_i = X'$;

 End if

End

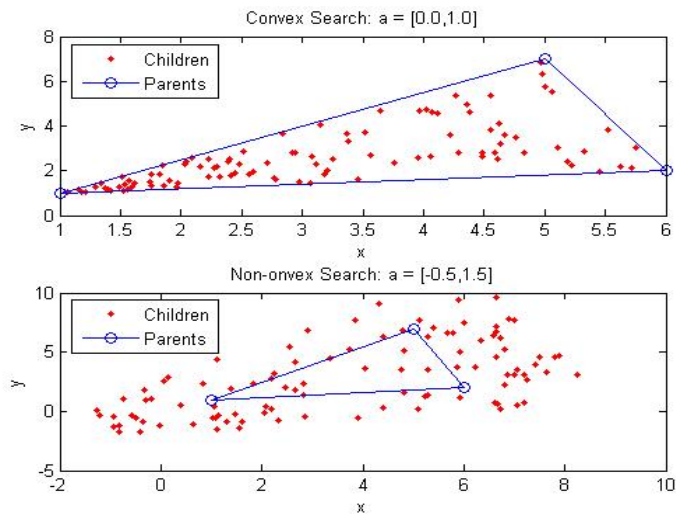


图 3.4 非凸区间搜索示意图

3.2.4.5 简化缩放因子

为了使算法简单易用和避免人为设置参数的不准确性, 在 ODE 中缩放因子 $F \in (0,1]$ 是一个一致均匀分布的随机数.

3.2.4.6 正交差分演化算法 ODE

ODE 算法与传统演化算法的大体流程一样, 都是借助生物演化的思想和原理来解决问题. 具体描述如下.

算法 4: 正交差分演化算法 ODE

```

群体随机初始化并计算群体中每个个体的适应值;
找出群体中最好最坏个体;
产生合适的正交表;
while 停机准则未达到 do
    执行算法 3, 产生新群体;
    找出当前群体最好最坏个体;
    执行算法 1 和算法 2 产生个体  $x$ ;
    if  $Better(x, x_{worst}) == true$  then
         $Pop[WorstIndex] = x$ ;
    End if
    显示计算结果;
End
```

注: 在以上算法中均是对最小化问题的描述. ODE 的停机准则是达到适应值最大评价次数或 $|f(x_{best}) - f(x_{worst})| < \varepsilon$.

§ 3.3 ODE 在函数优化中的应用

3.3.1 实验环境及参数设置

实验环境: CPU—PIV 2.8G; 内存—512M; 操作系统—Microsoft Windows 2000 Server; 开发语言—Microsoft Visual C++ 6.0.

所有实验采用相同的参数, 设置如下:

群体大小: $M=100$; 杂交概率: $CR=0.9$; DE 策略: DE/rand/1/exp; 适应值最大评价次数: $NFFE=100\ 000$; 父个体数目: $P=6$; 停机精度: $\varepsilon=1e-30$; 决策变量分块大小: 当自变量维数 $N>15$ 时, $F=2$; 其他, $F=N$.

3.3.2 测试函数

为了测试算法的性能, 笔者选用了 12 个标准测试函数 $f_{01} - f_{12}$. 此 12 个函数可以在文献 [37] 中得到, 文献 [37] 的实验结果是我在完成毕业论文期间与我的合作者的成果, 因此, 本文直接引用. 函数 $f_{01} - f_{06}$ 和 f_{09}, f_{10} 的维数 $N=30$; f_{07}, f_{08} 的维数 $N=100$; f_{11}, f_{12} 的维数 $N=4$. 函数 $f_{01} - f_{08}$ 是高维多峰多极值函数; f_{09}, f_{10} 是高维单峰函数, 而且为 f_{09} 噪声函数; f_{11}, f_{12} 是低维多峰少极值函数, 但是这两个函数极值点很苛刻, 许多算法都很容易陷入局部最优解.

3.3.3 实验结果

每个函数独立运行 50 次, 如下实验结果被统计: 1) 适应值函数平均评价次数 MFPE; 2) 函数平均最优值 Mean Best; 3) 标准方差 Std. Dev. 对函数 $f_{01} - f_{10}$, ODE 算法与传统 CDE 和 OGA/Q^[14]进行对比, 结果如表 3.1 所示; 对函数 f_{11} , f_{12} , 算法与 CDE 和 FEP^[48]进行对比, 结果如表 3.2 所示.

为了更直观地了解 ODE 算法的性能, 文章把 12 个函数的适应值—函数评价次数的演化曲线图列出, 图 3.5 – 图 3.16 中对 CDE 和 ODE 进行对比.

表 3.1 ODE、CDE 和 OGA/Q 的结果比较(黑体部分表示算法较好值)

F	MFPE			Mean Best			Std. Dev.		
	ODE	CDE	OGA/Q	ODE	CDE	OGA/Q	ODE	CDE	OGA/Q
f_{01}	47,980	72,100	302,166	-12569.5	-12569.5	-12569.4537	0	0	6.447×10^{-4}
f_{02}	36,430	159,600	224,710	0	0	0	0	0	0
f_{03}	57,850	206,300	112,421	5.89×10^{-15}	4.85×10^{-15}	4.44×10^{-16}	0	1.421×10^{-15}	3.989×10^{-17}
f_{04}	51,970	119,600	134,000	0	0	0	0	0	0
f_{05}	100,000	100,000	134,556	1.37×10^{-16}	5.24×10^{-15}	6.019×10^{-6}	7.249×10^{-17}	1.55×10^{-15}	1.159×10^{-6}
f_{06}	99,850	100,000	134,143	4.10×10^{-19}	6.59×10^{-13}	1.869×10^{-4}	2.772×10^{-19}	3.52×10^{-13}	2.615×10^{-5}
f_{07}	98,570	100,000	302,773	-97.211	-59.30467	-92.83	0.2988	0.830304	2.626×10^{-2}
f_{08}	98,570	100,000	245,930	-78.33233	-78.3254	-78.30	2.961×10^{-6}	0.001458	6.288×10^{-3}
f_{09}	100,000	100,000	112,652	6.63×10^{-4}	0.01647	6.301×10^{-3}	3.823×10^{-4}	0.004207	4.069×10^{-4}
f_{10}	100,000	100,000	112,612	0	1.665×10^{-8}	0	0	3.08×10^{-9}	0


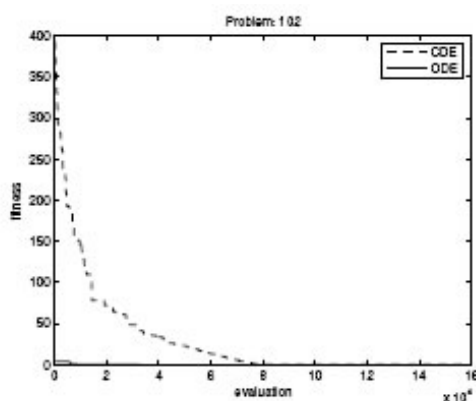
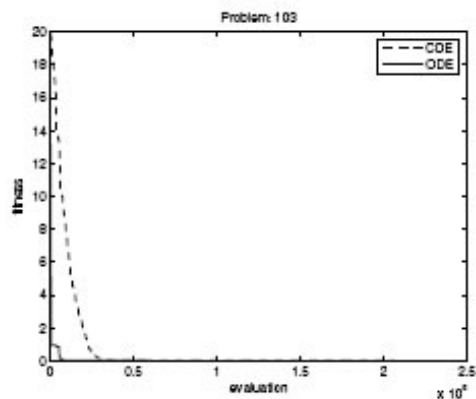


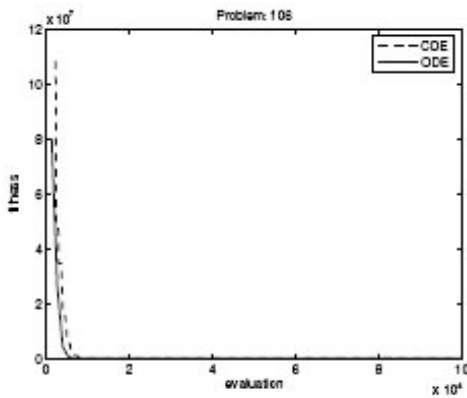
表 3.2 ODE、CDE 和 FEP 的结果比较(黑体部分表示算法较好值)

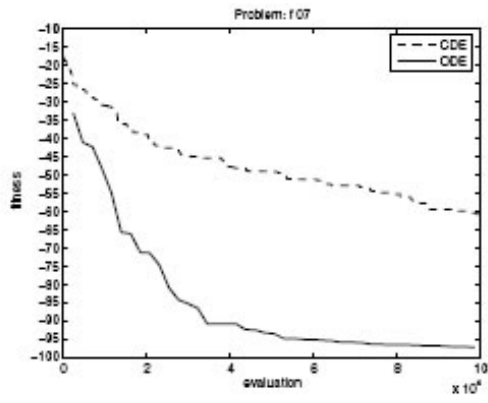





F	MFPE			Mean Best			Std. Dev.		
	ODE	CDE	FEP	ODE	CDE	FEP	ODE	CDE	FEP
f_{11}	6,640	7,100	10,000	-10.4029	-10.40285	-5.52	0	1.246×10^{-7}	2.12
f_{12}	7,030	7,900	10,000	-10.5364	-10.53638	-6.57	0	6.576×10^{-9}	3.14

3.3.4 结果分析

从表 1 和表 2 的统计结果可以看出: 1) ODE 算法可以找到所有函数的最优解或接近最优解; 2) 对函数 $f_{01}-f_{04}$ 和 $f_{10}-f_{12}$ 这六个函数, ODE 算法每次都能找出这些函数的最优解; 3) ODE 算法在 6 个函数($f_{01}, f_{05}-f_{09}$)上的平均最优值优于 OGA/Q 的值; 4) 对函数 f_{02}, f_{04} 和 f_{10} , ODE 算法和 OGA/Q 都找出了函数的最优解; 5) 除函数 f_{03} 的平均最优解稍差外, ODE 算法在其他 11 个函数的平均最优解均优于或等于 CDE 的解; 6) ODE 算法的适应值函数平均评价次数此处比 OGA/Q 的小, 而且与 CDE 相比也有所减少. 此外, 可以看出, ODE 算法在所有 12 个测试函数中, 其标准方差都是很小的, 除函数 f_{07} 的标准方差值大于 OGA/Q 的值外, 对函数 $f_{03}, f_{05}, f_{06}, f_{08}, f_{09}, f_{10}$ 的标准方差均小于 OGA/Q 的值, 其他 3 个函数的标准方差值两者相等, 均为 0; 而且, ODE 算法的标准方差值在所有测试函数上均优于或等于 CDE 的值; 7) 对于维数比较高的函数优化问题, ODE 算法的性能要明显优于 CDE 算法, 但是对于低维函数优化问题二者的性能比较接近; 8) ODE 算法的性能要明显优于 FEP 的性能, 不仅 ODE 算法每次都能找

到函数 f_{11} , f_{12} 的全局最优解, 而且函数的平均评价此处也小于 FEP 的平均评价次数. 从上面的分析可以看出, ODE 算法具有很好的稳定性, 同时又加快了算法的收敛和增强了全局搜索能力.

图 3.5 函数 f_{01} 演化曲线图图 3.6 函数 f_{02} 演化曲线图图 3.6 函数 f_{03} 演化曲线图图 3.8 函数 f_{04} 演化曲线图图 3.9 函数 f_{05} 演化曲线图图 3.10 函数 f_{06} 演化曲线图

图 3.11 函数 f_{07} 演化曲线图图 3.12 函数 f_{08} 演化曲线图图 3.13 函数 f_{09} 演化曲线图图 3.14 函数 f_{10} 演化曲线图图 3.15 函数 f_{11} 演化曲线图图 3.16 函数 f_{12} 演化曲线图

§ 3.4 小节

为了进一步加快 DE 算法的速度和增强其鲁棒性, 文章通过对 CDE 算法的改进, 把正交设计的方法应用到算法中, 通过 2 水平正交杂交算子和直观统计法产生子个体, 同时, 算法采用具有非凸搜索能力的混合杂交变异算子, 增强了算法非凸空间搜索能力. 通过采用决策变量分块策略, 减少了正交设计的因素个数, 从而可以设计较小的正交表进行实验, 减少了适应值的评价次数, 进一步加快了算法的速度. 通过 12 个不同类型的标准测试函数的测试, 并与其他算法进行比较, 其结果表明, ODE 算法不仅在 CDE 算法的基础加快了收敛速度, 同时在解的精度和稳定性上也有了明显的提高. 而且, 该算法的性能也优于所比较的 OGA/Q 算法.

由于 ODE 具有很优越的性能, 所以在本文将使用 ODE 算法设计演化 Kalman 滤波器. 这将在第四章中详细描述.

第四章 演化 Kalman 滤波器的设计及其应用研究

§ 4.1 相关工作

目前,对组合导航系统的主要要求是高精度、高可靠性、能够长时间连续工作、能够适应不同的路况和低成本。惯性导航系统(INS)与全球定位系统(GPS)都是常用的组合导航系统,由于它们具有很好的互补性,其组合可以大大提高导航系统的精度和可靠性,因此得到广泛的应用。

在组合导航系统中, Kalman 滤波技术得到广泛的应用。Kalman 滤波是关于状态最优估计的有效方法。当组合导航系统的数学模型(包括系统的动力学模型及系统噪声和量测噪声的统计特性等)精确已知,并忽略计算误差时,用常规 Kalman 滤波对系统的状态进行估计,可以得到状态的精确估计值,否则,如果模型不准确,滤波精度将会降低,甚至发散。其次,用正规 Kalman 滤波于目标定位和跟踪,其数学描述与实际物理过程往往不相符合,主要表现在:①目标机动如俯冲、盘旋、圆弧、比例导引等运动,已经破坏了目标运动假定,而使动态方程不再成立;②动态系统与量测噪声统计特性不再是均值为零的高斯白噪声序列;③坐标变换、误差协方差阵对称性、计算舍入误差、初始状态和初始误差协方差阵等引起的误差。由此可见,诸多因素破坏了 Kalman 滤波方程的准确性,因此需要对其进行校正。

建立组合导航系统准确的数学模型需要作大量的试验,尤其是建立准确的系统噪声和量测噪声的统计特性很困难。为了解决此问题,通常采用自适应滤波技术,在进行滤波的同时,利用观测数据带来的信息,不断地在线估计和修正模型参数、噪声统计特性以提高滤波精度,得到对象状态的最优估计值。

对 INS/GPS 组合导航系统而言,由于路况复杂性及 GPS 信号干扰的不确定性,其量测噪声统计特性随实际工作环境而改变,初始的先验值并不能代表实际工作时的噪声情况。经过对惯导系统的大量反复试验,可以获得工作时系统噪声的统计特性,但是实际工作时量测噪声的统计特性是未知的。针对此问题,主要提出的改进是在线估计量测噪声统计特性的自适应滤波方法。在进行滤波时,利用量测信息不断地在线估计量测噪声的统计特性,以得到系统状态变量的精确估计值。目前,自适应滤波的方法有很多, Kalman 滤波与模糊逻辑方法的组合使用,是比较理想的一种^[38]。但文献[38]中的方法每步都在量测噪声方差阵初始值的基础上进行调整,并不记忆此次调整之前的结果,容易引起调整后方差阵震荡,其模糊逻辑自适应控制器(FLAC)以滤波器残差的方差作为一个输入,使得必须为每一项具体应用专门设计 FLAC,弱化了其通用性。

针对上述问题, 文献[39]采用一种模糊自适应 Kalman 滤波技术, 根据实时得到的量测新息的实际方差与理论方差的比值, 由设计的模糊推理系统(FIS)在线实时调整量测噪声矩阵。这就使滤波算法不需要得到准确的量测噪声矩阵的先验知识, 且对于时变的量测噪声也能够得到精确的估计值。与文献[38]中方法相比, 采用递推的方式逐步调整系统量测噪声方差阵逼近真实值, 并可通过设定常参数 b 来调整逼近过程在快速性与稳定性之间达到最佳平衡。并且以量测新息的实际方差与理论方差的比值作为 FIS 的输入, 强化了方法的通用性。

但是, 采用模糊自适应推理需要很多经验数据, 这在航天器的导航应用中由于环境的改变可能会出现经验数据不准确, 因此, 有的学者采用遗传算法来估计组合导航系统惯性器件噪声统计模型参数。文献[40]设计了一种基于遗传算法的多模型 Kalman 滤波器。这里采用 Magill 的 Kalman 滤波器池方法^[41]含有一组成并行关系的 Kalman 滤波器, 每个滤波器使用未知参数的不同取值, 如图 4.1 所示。 ρ_i 为池中第 i 个滤波器所使用的滤波参数。最优估计 \hat{x}_k^{opt} 为 k 时刻池中各滤波器状态估计值的加权和。




图 4.1 多模型 Kalman 滤波池

文献[40]得出的结论是: 采用遗传算法的多模型自适应滤波方法不但可以得到很好的滤波精度, 而且还可以辨识出准确的滤波参数。因此, 基于遗传算法的多模型算法是一种非常有效的方法。但是, 如何更好的抑制遗传算法收敛于伪极值, 遗传算法寻优的周期、模型的个数、寻优的代数等参数的选定对于滤波器的效果和实时性能都有一定的影响, 这些问题都是需要反复调试和研究才能得到较好的结果, 这也就为采用其他更为先进的演化算法来优化 Kalman 滤波器的参数提供了空间。

文献[42, 43]中提出了一种基于演化算法的 Kalman 滤波器设计方法 (简称 SFKF), 并提出一种选择跟随(Selection Follower, SF)变异算子^[42, 43], 以提高算法的收敛速度和精度。同时, 作者采用均方差估计(Mean Square Error, MSE)作为适应值函数。通过几个测试用例, 并与期望最大(Expectation Maximization, EM)算法相比较, 指出 SFKF 在有效性和鲁棒性上要优于 EM 算法。但是, 在 SFKF 中, 没有考虑在 Kalman 滤波中系统过程噪声方差矩阵 Q_k 非负定

和系统观测噪声方差矩阵 R_k 正定的约束条件, 所以, SFMF 有可能会出现发散的情况^[6], 这将导致滤波过程的失败。

本文的研究在文献[42, 43]的基础之上, 把第三章中提出的 ODE 算法应用于 Kalman 滤波中, 并采用均方差估计(Mean Square Error, MSE)作为适应值函数, 同时, 考虑 Kalman 滤波中系统过程噪声方差矩阵 Q_k 非负定和系统观测噪声方差矩阵 R_k 正定的约束条件, 提出了演化 Kalman 滤波算法的基本框架, 并通过一种基于正交设计的演化 Kalman 滤波算法(ODEKF)验证了算法的有效性。

§ 4.2 演化函数优化与演化 Kalman 滤波器的关系

考虑如下随机线性离散系统(此处不考虑控制作用和噪声输入矩阵, 由于连续系统可以离散化, 因此在本文的研究中主要针对离散系统), 其方程如下

$$X_k = \Phi_{k,k-1} X_{k-1} + W_{k-1} \quad (4.1a)$$

$$Z_k = H_k X_k + V_k \quad (4.1b)$$

式中 X_k 是系统的 n 维状态向量, Z_k 是系统的 m 维观测向量, W_k 是系统的 n 维随机干扰向量, V_k 是系统的 m 维观测噪声向量, $\Phi_{k,k-1}$ 是系统的 $n \times n$ 维状态转移矩阵, H_k 是 $m \times n$ 维观测矩阵。式(4.1a)为动态系统状态方程, 式(4.1b)为系统观测方程。

关于系统过程噪声和观测噪声的统计特性, 作如下假定

$$\begin{cases} E[W_k] = 0, & E[W_k W_j^T] = Q_k \delta_{kj} \\ E[V_k] = 0, & E[V_k V_j^T] = R_k \delta_{kj} \\ E[W_k V_j^T] = 0 \end{cases} \quad (4.2)$$

其中 Q_k 是系统过程噪声 W_k 的 $n \times n$ 维对称非负定方差矩阵, R_k 是系统观测噪声 V_k 的 $m \times m$ 维对称正定方差矩阵, 而 δ_{kj} 是 Kronecker- δ 函数, 其定义为

$$\delta_{kj} = \begin{cases} 0 & k \neq j \\ 1 & k = j \end{cases} \quad (4.3)$$

Kalman 滤波问题是: 基于观测 (Z_1, Z_2, \dots, Z_t) , 求状态 X_t 的线性最小方差估值 \hat{X}_t ,

它的极小化性能指标为^[12]

$$J = E[(X_t - \hat{X}_t)(X_t - \hat{X}_t)^T] \quad (4.4)$$

在性能指标 (4.4) 下, 通过射影定理可以推导 (推导过程省略, 详细推导过程可参考文献[6, 12]) 出 Kalman 滤波的估计误差方差矩阵 P_k 为

$$\begin{aligned} P_k &= E[(X_t - \hat{X}_t)(X_t - \hat{X}_t)^T] \\ &= [I - K_k H_k] P_{k,k-1} [I - K_k H_k]^T + K_k P_k K_k^T \end{aligned} \quad (4.5)$$

式 (4.5) 正好是 Kalman 滤波基本方程式 (2.7) 的估计误差方差矩阵式 (2.7e)。由此可见, 要极小化性能指标式 (4.4) 只需要在使用 Kalman 滤波时极小化其估计误差方差矩阵 P_k 。

从上面的分析可以看出, 演化 Kalman 滤波器的设计主要任务就是优化出合适的参数使 Kalman 滤波器的估计误差方差阵最小, 并且能够随环境的改变自适应地改变参数 (适应值函数的设计将在 4.3 节中具体说明), 使滤波的性能最好。而使 Kalman 滤波器的估计误差方差阵最小可以通过选用不同的适应值函数来实现, 但其最终目的都是一致的, 即极小化其估计误差方差阵, 这实际上就是一个最小化优化问题, 这与第三章中提到的函数优化有相同之处, 这也是为什么在第三章中提出 ODE 算法后, 先用函数优化实例进行验证的原因。

§ 4.3 演化 Kalman 滤波器的设计

4.3.1 演化 Kalman 滤波器的原理

4.3.1.1 适应值函数的设计

要设计演化 Kalman 滤波器, 首先得考虑其适应值函数的选取。

由 4.2 节的分析可以看出, 演化 Kalman 滤波器的设计实际上与函数优化有紧密的联系, 可以把演化 Kalman 滤波器转化成一个函数最小化优化问题。在设计演化 Kalman 滤波器时, 首先由第二章 2.2.2 节 Kalman 滤波的特点 (2) 可以知道: 在求解滤波器增益的过程中, 随时可以算得滤波器的精度指标 P_k , 其对角线上的元就是滤波误差向量各分量的方差。所以, 在演化 Kalman 滤波器中设计适应值函数如下:

$$X.f = \sum_{k=1}^N \left(\sum_{s=1}^n p_{kss} \right) \quad (4.6)$$

其中 N 表示动态系统状态的个数, n 为动态系统的维数, p_{kss} 表示动态系统中第 k 个状态

P_k 的对角线上第 s 个元素, $X.f$ 表示个体 X 的目标函数适应值。

当然, 如果在知道了系统的准确方程 (即不含噪声的方程) 之后, 也可以使用最小二乘误差作为适应值函数, 如下所示:

$$X.f = \sum_{k=1}^N (X_k - \hat{X}_k)^2 \quad (4.7)$$

为了研究简单起见, 本文的研究中采用式 (4.7) 作为适应值函数。

4.3.1.2 编码及解码设计

在演化算法中, 个体都采用一定的编码形式的表示, 如二进制编码、实数编码等, 不同的编码有各自的优缺点, 同时也有相应的遗传操作算子。在本文所设计的演化 Kalman 滤波器中, 个体的编码采用实数编码, 其原因主要是: 1) 差分演化算法的个体编码是采用实数编码, 便于算法的实现; 2) 本文所设计的演化 Kalman 滤波器主要针对的是工程应用, 而在工程应用中对算法的效率和运算速度是很重要的, 而采用实数编码可以避免其他编码在解码过程中消耗的时间, 从而可以加快算法的运行速度; 而且, 实数编码也更适合实数型的工程应用 (Kalman 滤波中各数据都是采用实数来表示的)。

在文献[42, 43]中, 需要编码的矩阵有 $n \times n$ 维的状态转移矩阵 $\Phi_{k,k-1}$, $m \times n$ 维的观测矩阵 H_k , $n \times n$ 维的非负定系统过程噪声矩阵 Q_k 和 $m \times m$ 维的正定系统观测噪声矩阵 R_k , 因此 SFMF 中, 每个个体长度为

$$Num_1 = n \times n + m \times n + \sum_{i=1}^n i + \sum_{j=1}^m j \quad (4.8)$$

即在 SFKF 中问题求解空间是 Num_1 维。由式(4.8)可以看出, 当 n 和 m 比较大时, 计算是很耗时的, 而且会加大问题的复杂性, 这将会失去 Kalman 滤波的实时性的特点, 不利于工程应用。而在实际工程应用中, 一般来说状态转移矩阵 $\Phi_{k,k-1}$ 和观测矩阵 H_k 是可以准确给出的 (如在太空中的飞行器, 在不考虑噪声的情况下, 其飞行为一条抛物线轨道), 但是, 系统过程噪声矩阵 Q_k 和系统观测噪声矩阵 R_k 则是很难确定的, 在现在的一些导航系统中, 一般都是采用一些经验值或者是一些是在地面静态环境下测得的值, 这些值不能很好反映环境的变化, 从而会是导航精度下降。所以, 在本文的研究中只对系统过程噪声矩阵 Q_k 和系统观测噪声矩阵 R_k 进行编码, 而状态转移矩阵 $\Phi_{k,k-1}$ 和观测矩阵 H_k 则不参与编码, 它们是

通过工程人员给出的。这样, 本文中所设计的演化 Kalman 滤波的个体长度为

$$Num_2 = \sum_{i=1}^n i + \sum_{j=1}^m j \quad (4.9)$$

显然其长度 $Num_2 < Num_1$, 从而减少了编码的长度, 同时减少了算法的搜索空间, 加快了算法的运行速度, 而这对工程应用是十分重要的。

由于在演化算法中个体 $D = (d_1, \dots, d_{\frac{n(n+1)}{2}}, d_{\frac{n(n+1)}{2}+1}, \dots, d_{\frac{n(n+1)+m(m+1)}{2}})$ 采用的线性编码, 所以, 为了能够使个体应用到 Kalman 滤波中必须对个体 D 进行解码。在解码时, 按照对称矩阵的特征, 把前 $n(n+1)/2$ 个数据作为系统过程噪声矩阵 Q_k 的元素, 对其上三角矩阵按行从左到右从上到下解码, 然后转化成对称矩阵 Q_k ; 对 D 的后 $m(m+1)/2$ 个作为系统观测噪声矩阵 R_k 的元素, 按照同样的方法把它们转化成对称矩阵 R_k 。

4.3.1.3 约束条件

由于 Kalman 滤波的系统过程噪声矩阵 Q_k 是非负定的, 系统观测噪声矩阵 R_k 是正定的, 所以, 演化群体中每个个体通过解码后都必须满足 Q_k 非负定和 R_k 正定的条件, 即这些条件形成了演化 Kalman 滤波的约束条件。因此, 演化 Kalman 滤波问题就可以转换成一个带约束的函数优化问题, 这就可以利用第三章提出的改进的差分演化算法(ODE)来求解 (当然, 也可以采用其他演化算法来求解)。由线性代数的知识可知, 对于系统过程噪声矩阵 Q_k 要满足非负定的条件只需要 Q_k 的每个主子式均大于或等于 0 即可; 而对于系统观测噪声矩阵 R_k 要满足正定的条件需要 R_k 每个主子式均大于 0。所以, 总的约束函数个数为

$$Num_con = n + m \quad (4.10)$$

4.3.1.4 搜索空间

对于每一个优化问题都有一定的搜索空间, 搜索空间是由优化问题所涉及的自变量的范围来确定的。在演化 Kalman 滤波中, 搜索空间是由组成系统过程噪声矩阵 Q_k 和系统观测噪声矩阵 R_k 里面元素的范围所确定, 由于 Kalman 滤波问题的特殊性, 一般来说工程人员都

可以给出一个相对较小且较精确的自变量范围,所以,这对演化算法的搜索是很有帮助的,群体中的个体在较小的范围内进行搜索,可以加快搜索到全局解的速度,从而达到工程应用的实时性要求。

4.3.1.5 停机条件

在本文的研究中采用最大演化代数作为停机条件。一般为了使算法能够运行较快,在初始化时可以把经验值作为初始种群的一个个体,此时,演化代数可以设置小一些,以节省运算时间。由于在传统的 Kalman 滤波器中,工程人员都必须提供一个 Q_k 和 R_k 的值(称为经验值),这样把经验值作为群体中的一个个体,既可以保证演化 Kalman 滤波的精度不会低于传统的滤波算法,又可以加快算法的收敛速度,我们称之为演化 Kalman 滤波的**保底策略**。

4.3.1.6 演化 Kalman 滤波算法(EvoKF)

演化 Kalman 滤波算法的流程与传统演化算法的流程基本一样:

- a) 群体初始化。在传统的演化算法中一般都采用随机初始化方法来生成初始群体,在文献[14]中 Y. W. Leung 和 Y. Wang 提出一种新的群体初始化方法,即采用正交实验设计方法来产生初始群体,我们称之为群体的正交初始化。在本文的研究中采用文献[14]中提出的正交初始化方法来产生初始群体。
- b) 解码与群体适应值的计算。由于在 Kalman 滤波中系统过程噪声矩阵 Q_k 和系统观测噪声矩阵 R_k 均是矩阵,所以在计算群体中个体适应值之前必须对每个个体进行解码,解码方法采用上文中提出的方法。个体解码之后即可由式(4.6)来计算其目标函数适应值 $X.f$,并根据矩阵主子式大于或等于零来计算约束函数适应值,并由第三章中式(3.9)来计算个体总的约束适应值 $X.cf$ 。
- c) 判断是否满足终止条件,如果满足则退出程序;否则,继续执行下面的步骤。
- d) 通过遗传算子(杂交、变异等)产生新的个体。
- e) 利用选择算子选择个体形成新的群体。返回步骤 c)。

基本演化 Kalman 滤波的流程图如图 4.2 所示




图 4.2 基本演化 Kalman 滤波算法流程图

4.3.2 基于 ODE 算法的演化 Kalman 滤波

正如前面所提及的，在演化 Kalman 滤波中可以使用多种方法，如遗传算法、演化策略、进化规划、差分演化算法等。本文的研究中主要是使用基本差分演化算法和第三章中提出的改进差分演化算法来进行研究。基于改进差分演化算法的演化 Kalman 滤波简称为 ODEKF。在 ODEKF 中初始群体采用正交初始化的方法产生，并结合基本差分演化算法中的 DE/rand/1/exp 策略和第三章中提出的正交杂交算子来产生新个体，其他步骤与基本差分演化算法相同。ODEKF 的算法流程图如图 4.3 所示。




图 4.3 ODEKF 算法流程图

§ 4.4 演化 Kalman 滤波算法(EvoKF)的应用

4.4.1 EvoKF 的基本应用

4.4.1.1 郭涛算法简介

为了能进一步证明演化 Kalman 滤波的有效性,在本文的研究中还把郭涛算法^[46]应用于 4.2 节所提出的演化 Kalman 滤波中。基本郭涛算法如下所述:

基本郭涛算法: 基本郭涛算法流程图

Begin

```

1  Initialize  $P=\{X_1, X_2, \dots, X_N\}$ ;
2   $gen := 0$ ;
3   $X_{best} = \arg \max_{1 \leq i \leq N} f(X_i)$ ;
4   $X_{worst} = \arg \min_{1 \leq i \leq N} f(X_i)$ ;
5  while  $\text{abs}(f(X_{best})-f(X_{worst})) > \varepsilon$  and  $gen < \text{MaxGen}$  do
6      从群体  $P$  中随机选择  $M$  个个体  $X_1', X_2', \dots, X_M'$ , 形成子空间  $V$ ;
7      从子空间  $V$  中随机选择  $S$  个个体  $Y_1', Y_2', \dots, Y_S'$ ;
8       $X_{worst} = \arg \min_{1 \leq i \leq N} f(X_i)$ ;
9      if  $\text{Better}(X', X_{worst})$  then  $X_{worst} = X'$ ;
10     从群体中随机选择  $T$  个个体 (不包括  $X_{best}$ );
11     使用修正算子对这些个体进行一定的修正;
12      $gen := gen + 1$ ;
13      $X_{best} = \arg \max_{1 \leq i \leq N} f(X_i)$ ;
14      $X_{worst} = \arg \min_{1 \leq i \leq N} f(X_i)$ ;
15  od
16  print  $gen, X_{best}, f(X_{best})$ ;
End
```

郭涛算法的特点为:

- 1) 算法采用了演化算法中的群体搜索策略, 保证了搜索空间的全局性, 有利于搜索问题的最优解。
- 2) 算法采用了随机子空间的随机搜索, 并采用多父体杂交和非凸子空间搜索策略, 从而保证了随机搜索的遍历性。
- 3) 算法采用了“劣汰策略”, 每次只淘汰群体中最坏的个体, 淘汰压力小, 从而保证了群体的多样性。同时, 这样的策略也可以保证上一个群体的最好个体始终完好无缺地在下一个群体中出现, 而这样做就可以保证算法以概率 1 收敛到全局最优解^[4]。
- 4) 算法采用的是群体爬山策略, 保证了整个群体最后集体登上最高峰 (深谷)。当最优解不唯一时, 该算法还可能一次同时找到多个最优解^[46]。

4.4.1.2 实验环境及参数设置

实验环境: CPU—PIV 2.8G; 内存—512M; 操作系统—Microsoft Windows XP SP2; 开发语言—Standard C++ in Microsoft Visual C++ 6.0.

在本文的研究中,把利用 DE/rand/1/exp 策略的基本差分演化算法(DE)、基本郭涛算法(GT)和第三章中提出的正交差分演化算法(ODE)用在演化 Kalman 滤波中,以测试演化算法的性能,同时,把这三个算法的结果进行比较,以验证进一步 ODE 算法的有效性,以便在今后的试验中使用。所有实验采用的参数,设置如下:

- 1) DEKF 算法: 群体大小: $M=100$; 杂交概率: $CR=0.9$; DE 策略: DE/rand/1/exp; 适应值最大评价次数: $NFFE=5\ 000$; 停机精度: $\varepsilon=1e-30$ 。
- 2) GTKF 算法: 群体大小: $M=100$; 适应值最大评价次数: $NFFE=5\ 000$; 父个体数目: $P=3$; 停机精度: $\varepsilon=1e-30$ 。
- 3) ODEKF 算法: 群体大小: $M=100$; 杂交概率: $CR=0.9$; DE 策略: DE/rand/1/exp; 适应值最大评价次数: $NFFE=5\ 000$; 父个体数目: $P=3$; 停机精度: $\varepsilon=1e-30$; 决策变量分块大小: $F=7$ 。

4.4.1.3 实验测试用例

在本文的研究中采用的测试用例来自文献[47],其描述为:设信号源运动方程为 $s(t)=5-2t+3t^2+v(t)$,其中 $v(t)$ 均值为 0,方差为 δ 的高斯白噪声。

状态向量为 $X_k=(s,s',s'')^T$,其中 s 表示信号源 k 时刻运动位置, s' 表示信号源 k 时刻运动速度, s'' 表示信号源 k 时刻运动加速度。取初值 $X_0=(0.0,0.0,0.0)^T$ 。

状态转移矩阵为:

$$\Phi = \Phi_{k,k-1} = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix}$$

其中 T 为采样间隔,在本文的研究中取 $T=0.05$ 。

动态系统的维数为 $n=3$,观测系统的维数为 $m=1$,所以,在演化 Kalman 滤波中自变量维数为 7。

观测矩阵为 $H=H_k=(1,0,0)$ 。

初始估计误差协方差矩阵取

$$P_0 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

其中第一个元素取零主要是避免 P_0 为零矩阵,没有具体物理意义,即在本文的研究中

可以取 P_0 任意非零矩阵。

系统过程噪声矩阵 Q 和系统观测噪声矩阵 R 在演化 Kalman 中由算法优化确定。因此演化 Kalman 滤波实际上是一个参数估计问题, 这可以转换为函数优化问题求解, 即使适应值函数最小化。

由于本文的研究主要致力于工程应用, 因此, 此处把经验值作为演化 Kalman 滤波初始群体中的第一个个体, 起到保底作用。此处的实验分两大部分: 一部分假设经验值估计较为准确, 即系统观测噪声 $H = \delta^2$; 另一部分假定经验值估计不准确, 取系统观测噪声 $H = 10$ 。

在所有的实验中系统过程噪声 $Q = \begin{bmatrix} 0.25 & 0 & 0 \\ 0 & 0.25 & 0 \\ 0 & 0 & 0.25 \end{bmatrix}$ 。

$v(t)$ 高斯白噪声方差 δ 取 1, 2, 5, 10 分别进行实验。个体每维自变量范围均为 $[0, \delta^2]$ 。

4.4.1.4 实验结果

设利用式 (4.7) 计算得到观测数据未滤波时的最小二乘误差之为 a , 滤波后的最小二乘误差之为 b , 采用基本 Kalman 滤波过滤后的最小二乘误差之为 c , 采用演化 Kalman 滤波过滤后的最小二乘误差之为 d 。

【定义 1】 算法优化效率 λ :

$$\lambda = \frac{a-b}{a} \times 100\% \quad (4.11)$$

【定义 2】 演化算法改进效率 η : 即演化 Kalman 滤波最小二乘误差相对于基本 Kalman 滤波最小二乘误差的改进效率, 定义为

$$\eta = \frac{c-d}{a} \times 100\% \quad (4.12)$$

每个函数独立运行 30 次, 如下实验结果被统计: 1) 最优演化算法改进效率 Best; 2) 平均演化算法改进效率 Mean; 3) 最差演化算法改进效率 Worst; 4) 标准方差 Stdv. 表 4.1-表 4.4 表示在经验值估计准确时在不同噪声下各算法的改进效率值; 表 4.5-表 4.8 表示在经验值估计不准确时在不同噪声下各算法的改进效率值。图 4.4-图 4.9 分别表示在方差 δ 取 1, 2, 5, 10, 20 和 50 时 ODEKF 的滤波结果曲线图。

(1) 经验值估准确

当经验值估计准确, 即系统观测噪声 $H = \delta^2$, 当 $v(t)$ 高斯白噪声方差 δ 取 1, 2, 5, 10, 实验结果分别如表 4.1 – 表 4.4 及图 4.4 – 图 4.7 所示。

表 4.1 $\delta = 1$ 时各算法改进效率值 (黑体部分表示算法得到的较好结果)

	高斯白噪声方差 $\delta = 1$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	18.5379	14.3564	9.3953	0.23051
GTKF	20.4623	12.0453	6.9697	0.3004
ODEKF	21.3671	15.529	10.8435	0.2325

表 4.2 $\delta = 2$ 时各算法改进效率值 (黑体部分表示算法得到的较好结果)

	高斯白噪声方差 $\delta = 2$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	11.6273	7.7617	2.5272	0.21335
GTKF	12.353	7.4193	2.4353	0.29515
ODEKF	12.9915	8.1211	4.5926	0.17799

表 4.3 $\delta = 5$ 时各算法改进效率值 (黑体部分表示算法得到的较好结果)

	高斯白噪声方差 $\delta = 5$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	9.596	3.4099	0	0.27562
GTKF	18.6108	8.2628	0.9732	0.42488
ODEKF	20.7069	8.7535	3.0199	0.33079

表 4.4 $\delta = 10$ 时各算法改进效率值 (黑体部分表示算法得到的较好结果)

	高斯白噪声方差 $\delta = 10$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	1.7811	0.4978	0	0.07724
GTKF	16.2873	7.244	2.1693	0.33867
ODEKF	17.2812	8.8803	4.3958	0.29046

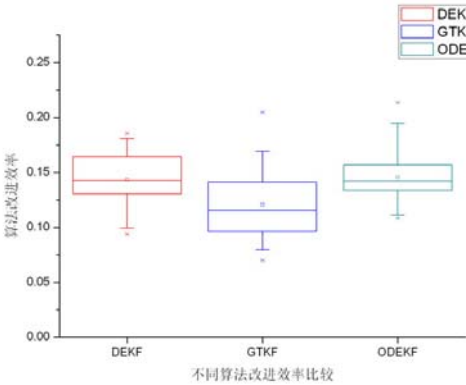


图 4.4 $\delta = 1$ 时各算法改进效率值

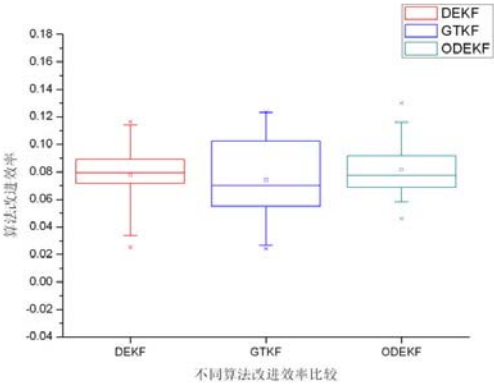
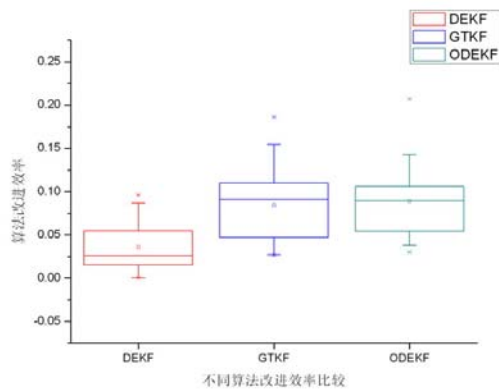



图 4.5 $\delta = 2$ 时各算法改进效率值

图 4.6 $\delta = 5$ 时各算法改进效率值图 4.7 $\delta = 10$ 时各算法改进效率值

(2) 经验值估计不准确

当经验值估计准确, 设系统观测噪声 $H = 10$, 当 $v(t)$ 高斯白噪声方差 δ 取 1, 2, 5, 10, 实验结果分别如表 4.5 – 表 4.8 及图 4.8 – 图 4.11 所示。

表 4.5 $\delta = 1$ 时各算法改进效率值(黑体部分表示算法得到的较好结果)

	高斯白噪声方差 $\delta = 1$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	42.2406	33.2406	23.9864	0.42866
GTKF	39.3717	30.9717	20.0379	0.45565
ODEKF	45.5198	34.0818	24.5347	0.45402

表 4.6 $\delta = 2$ 时各算法改进效率值(黑体部分表示算法得到的较好结果)





	高斯白噪声方差 $\delta = 2$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	16.5673	11.3723	6.1858	0.37322
GTKF	16.5563	11.0596	6.1858	0.28599
ODEKF	17.2899	12.1411	6.1321	0.3144

表 4.7 $\delta = 5$ 时各算法改进效率值(黑体部分表示算法得到的较好结果)

	高斯白噪声方差 $\delta = 5$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	8.3954	5.0117	1.628	0.17658
GTKF	13.9317	9.6776	2.0454	0.32814
ODEKF	10.4914	7.3677	2.937	0.21777



表 4.8 $\delta = 10$ 时各算法改进效率值(黑体部分表示算法得到的较好结果)



	高斯白噪声方差 $\delta = 10$ 时各算法改进效率值 (%)			
	Best	Mean	Worst	Stdv
DEKF	11.1005	4.9529	0	0.2509
GTKF	15.3911	7.3918	0.9059	0.42152
ODEKF	16.7477	9.746	1.92	0.239



图 4.8 $\delta = 1$ 时各算法改进效率值图 4.9 $\delta = 2$ 时各算法改进效率值图 4.10 $\delta = 5$ 时各算法改进效率值图 4.11 $\delta = 10$ 时各算法改进效率值

(3) 在不同噪声下 ODEKF 的滤波曲线图

为了进一步说明 ODEKF 的性能, 本文采用 (即方差 δ 取 1, 2, 5, 10, 20 和 50) 不同噪声下利用 ODEKF 进行了测试, 其结果如图 4.12 - 图 4.17 分别表示在方差 δ 取 1, 2, 5, 10, 20 和 50 时 ODEKF 的滤波结果曲线图。其中图 4.12-4.14 是在噪声比较小的情况下, ODEKF 的滤波结果, 一般情况下, 工程应用中的噪声都是比较小的, 从图中可以看出 ODEKF 的滤波结果与真实值十分接近。图 4.15-4.17 是噪声较大情况下 ODEKF 的滤波结果, 由于系统过程噪声很大, 所以观测值与真实值相差很大, 但是, 从图 4.15-4.17 可以看出, ODEKF 的滤波性能仍然很好, 其滤波后的结果与真实值很接近。

图 4.12 噪声 $\delta = 1$ 时 ODEKF 的滤波曲线图图 4.13 噪声 $\delta = 2$ 时 ODEKF 的滤波曲线图

图 4.14 噪声 $\delta = 5$ 时 ODEKF 的滤波曲线图图 4.15 噪声 $\delta = 10$ 时 ODEKF 的滤波曲线图

图 4.16 噪声 $\sigma = 20$ 时 ODEKF 的滤波曲线图图 4.17 噪声 $\sigma = 50$ 时 ODEKF 的滤波曲线图

4.4.1.5 实验结果分析

从表 4.1-表 4.8 和图 4.4-图 4.17 可以看出:

- (1) 在经验值估计较为准确的情况下, 从表 4.1-表 4.4 及图 4.4 – 图 4.7 可以看出, DEKF 的平均改进效率值 η 在[0.4978, 14.3564]范围内, 而且平均改进效率值随噪声的增大而降低; GTKF 的平均改进效率值 η 在[7.244, 12.0453]范围内, 相对较稳定, 且最大平均改进效率为 20.4623; ODEKF 的平均改进效率值 η 在[8.1211, 12.529]范围内, 相对较稳定, 且最大平均改进效率为 21.3671。但在总体趋势上, 三个算法的改进效率值都随着噪声的增大而逐渐降低。这是很合理的, 因为随这噪声的不断增大, 演化 Kalman 滤波所调用的 Kalman 滤波器的滤波性能就已经不是很稳定, 即使演化算法能够优化出较好的 Q 和 R 值。特别是当噪声增大到一定的程度时或超过噪声的范围之后, 在工程应用中已经可以通过其他的方式进行控制。所以, 从总体来说, GTKF 和 ODEKF 既有较好的滤波性能, 即使在初始经验值估计较为准确的情况下仍然能提高滤波效率 10%左右, 而且, ODEKF 的最差改进效率也在 3.0199%以上。
- (2) 当经验值估计不准确时, 从表 4.5-表 4.8 及图 4.8 – 图 4.11 可以看出, 由于经验值给定不准确, 导致 Kalman 滤波的性能已明显降低, 此时, 演化 Kalman 滤波的改进性能明显提升。特别是在噪声 $\delta=1$ 的时候, 平均改进效率在 30.9717%以上。而且 ODEKF 的平均改进效率在 9%以上。但是, DEKF 的改进效率不是很好, 在噪声比较大时, 有的情况下其性能与 Kalman 滤波的性能一样。在总体趋势上, 三个算法的改进效率值都随着噪声的增大而逐渐降低。由此可见, 在经验值估计不准确的情况下, 演化 Kalman 滤波器可以使滤波性能得到很大提高。
- (3) 从图 4.12-图 4.17 可以看出, ODEKF 的滤波曲线能较好的拟合原始无噪声数据, 特别是随着滤波的进行, ODEKF 的曲线与原始曲线基本重合, 且滤波的性能受噪声大小的影响不大, 即 ODEKF 的滤波可以很好的控制基本 Kalman 滤波的发散性。这表明 ODEKF 在改进基本 Kalman 滤波性能上具有很好的效果, 有望在工程中进一步应用。

4.4.2 EvoKF 在组合导航中的应用初探

组合导航方面, 目前国内学者侧重研究智能信息融合自适应卡尔曼滤波技术, 它是目前组合导航算法的一个新的发展方向, 它将模糊推理, 神经网络技术及信息融合技术应用到卡尔曼滤波器的设计当中。卡尔曼滤波算法是组合导航系统中最常用的算法。它根据对系统内在机理和噪声信息的分析, 采用一组递推算法, 经过时间更新和测量更新运算, 实现系统状态的最优估计。由于间接组合导航系统中采用的系统误差方程可简化为线性方程, 所以线性卡尔曼滤波器(LKF) 是目前国内组合导航研究中应用最广泛的算法, 但是它仍然存在如下问题需要进一步解决: (1) 非线性问题; (2) 计算误差和维数灾难; (3) 模型误差和系统发散; (4) 滤波器容错性与精度较差等。

针对以往卡尔曼滤波器误差产生的不同原因, 采取智能技术调控相应的计算环节, 在不

损失原有滤波器估计精度的基础上, 提高系统对各种干扰的适应性, 抑制卡尔曼滤波器发散。其中模糊控制自适应算法采用模糊控制器调整卡尔曼滤波器, 模糊控制器的输入可以采用滤波器新息状态或外系统工作状态, 输出可以直接进行增益计算或模型调整等, 模糊规则的建立将是该技术设计应用的关键。神经网络自适应算法应用方式灵活, 它在模型调整和组合导航系统故障检测和隔离中的应用值得关注。自适应神经网络模糊推理自适应算法将模糊控制的知识融入到神经网络之中, 利用神经网络自适应地自动产生规则和精练模糊规则, 解决规则的获取和调节问题, 生成的经验规则推理, 构成了一个带有人类感觉认知方式的自适应组合导航系统, 这一方法将成为本领域今后十分重要的研究方向之一。

演化计算在惯性导航系统的研究国内外都处于起步阶段。英国 Plymouth 大学的 D.Leobis 教授提出基于演化计算的滤波算法用于水下无人艇的惯性导航系统研制^[44], 加拿大 Ucalgary 学院 M. A. Hassanain 博士发表了基于演化计算的惯性/GPS 组合导航系统^[45]等。

从 ODEKF 的基本应用可以看出, 演化算法可以提高 Kalman 滤波的精度, 同时可以增强 Kalman 滤波的自适应性, 所以, 这里对基于 EvoKF 的 INS/GPS 组合导航系统进行初探, 在未来的工作中我们将做进一步的工作, 其中包括算法实现和实物跑车来验证算法的有效性。基于 EvoKF 的 INS/GPS 组合导航系统的基本原理图如图 4.10 所示。




图 4.10 基于演化 Kalman 滤波的 INS/GPS 组合导航系统

演化 Kalman 滤波通过优化 GPS/INS 的残差来优化整个滤波的性能。GPS/INS 的残差通过下面的公式来定义^[39]:

新息序列(残差序列)为 r_k :

$$r_k = Z_k - H_k X_{k,k-1} \quad (4.11)$$

残差方差的理论值定义为 p_r :

$$p_r = H_k (\Phi P_k \Phi^T + \Gamma Q \Gamma^T) + R_{k-1} \quad (4.12)$$

定义残差的实际方差为 c_r .

$$c_r = \frac{1}{M} \sum_i^k r_i r_i^T \quad (4.13)$$

定义残差实测方差与理论方差的比值为 ROR_k :

$$ROR_k = \frac{Tr(c_r)}{Tr(p_r)} \quad (4.14)$$

其中, $Tr(\bullet)$ 表示对矩阵求迹。

通过演化算法自适应调节滤波过程中的各噪声的统计特性值, 使 ROR_k 始终保持在 1 附近, 从而可以提高滤波的精度, 并达到对滤波过程的实时调整。因此, 在基于 EvoKF 的 INS/GPS 组合导航系统中可以式 (4.14) 定义的残差实测方差与理论方差的比值为 ROR_k 来作为适应值函数, 其编码和解码方法以及约束函数适应值的计算均可采用 4.2 节中的方法。

§ 4.5 小结

本章在分析基本 Kalman 滤波的实质的基础之上, 提出了演化 Kalman 滤波的基本框架, 设计了相应的适应值评价函数、个体编码和解码方法和约束条件的处理等。为了验证演化 Kalman 滤波的性能, 把基本差分演化算法、郭涛算法和第三章中提出的正交差分演化算法应用于演化 Kalman 滤波中, 形成三种演化 Kalman 滤波方法: DEKF、GTKF 和 ODEKF。把这三种方法应用于一个测试用例中, 通过三种方法在不同噪声条件下验证了演化 Kalman 滤波算法的有效性。这为其他演化算法或群智能算法在 Kalman 滤波中的应用提供了参考。

在演化 Kalman 滤波的基础上, 本文还对演化 Kalman 滤波在 INS/GPS 组合导航中的应用进行了初探, 提出了基于演化 Kalman 滤波的 INS/GPS 组合导航系统的基本原理。

第五章 全文总结

演化算法是一种基于群体的启发式搜索算法, 它利用群体中的个体在解空间中进行搜索, 具有自适应、自学习、自组织和隐并行性等特点。在演化过程中, 群体中的个体通过遗传算子产生新个体, 保持群体的多样性, 对新的空间进行搜索, 以得到问题的最优解。自诞生以来就被用于求解优化问题, 直到现在, 求解优化问题仍然是演化计算的一个重要目标, 已被成功的应用于求解许多复杂模型的参数优化问题。演化计算不依赖于具体的模型表达式, 也不要求模型具有连续、可导的性质。

Kalman 滤波是一种时域滤波方法, 采用状态空间方法描述系统, 算法采用递推形式, 数据存储量小, 不仅可以处理平稳随机过程, 也可以处理多维和非平稳随机过程, 因此适用范围比较广泛。Kalman 滤波理论被用于随机最优控制问题、故障诊断等应用领域, 其中组合导航系统中的设计是其成功应用的一个最主要方面。

本文首先介绍了演化算法、优化计算和 Kalman 滤波的一些基本知识; 讨论了差分演化算法的基本原理并对其进行了改进, 通过一些标准函数的测试验证了其性能。随后, 本文指出了演化函数优化与演化 Kalman 滤波之间的关系, 提出了演化 Kalman 滤波的基本原理, 包括适应值函数的设计、个体的编码与解码、约束条件的处理、搜索空间的确定和算法的停机条件等。为了验证演化 Kalman 滤波的合理性, 本文把郭涛算法、基本差分演化算法和改进差分演化算法应用于演化 Kalman 滤波中, 并通过一个仿真实例对这三个算法进行了测试。实验结果表明, 三个算法的滤波结果均优于基本 Kalman 滤波的结果, 特别是在基本 Kalman 滤波的经验值选取不准确时, 演化 Kalman 滤波的改进效率更为显著。在这三个算法中, 基于改进差分演化算法的演化 Kalman 滤波的改进性能最优, 平均改进效率在 10% 以上, 尤其是在噪声比较小的时候其最优滤波结果比基本 Kalman 滤波要提高 30% 以上。

本文的主要工作和创新如下:

- 1) 提出将正交设计方法应用于差分演化算法中, 并提出了带约束的二水平正交杂交算子和决策变量分块策略, 加快了算法的收敛速度。同时, 设计了一种新的简单多样性规则以增强算法对约束条件的处理。为了增强算法对非凸问题的处理能力, 提出一种混合杂交-变异算子。简化了基本差分演化算法中的缩放因子, 以方便工程应用。
- 2) 指出了演化函数优化与演化 Kalman 滤波之间的关系。提出了演化 Kalman 滤波的理论框架, 设计了相应的适应值评价函数、个体编码解码方法、约束条件的处理、搜索空间的确定和算法的停机条件等。
- 3) 提出一种保底策略, 即把基本 Kalman 滤波的经验值作为演化算法的一个个体, 这样既可以保证演化 Kalman 滤波的性能不会低于基本 Kalman 滤波的性能, 又能减少演化 Kalman 滤波的适应值评价次数。这与实际工程应用更密切。设计演

化 Kalman 滤波性能评价标准, 并通过一个仿真实例以及把郭涛算法、基本差分演化算法和改进差分演化算法应用于演化 Kalman 滤波中, 验证了演化 Kalman 滤波理论框架的正确性和有效性。

- 4) 对基于演化 Kalman 滤波的 INS/GPS 组合导航系统的原理进行了初探, 提出了相应的原理框架。但其性能有待验证。

未来工作及设想:

- 1) 通过仿真实例测试基于演化 Kalman 滤波的 INS/GPS 组合导航系统原理的正确性。并通过室外跑车实验验证该滤波算法的有效性。
- 2) 对演化 Kalman 滤波的理论进行探讨, 证明其稳定性和收敛性等。

致谢

首先衷心感谢我的导师蔡之华教授。在我的三年研究生学习、生活和科研中以及在本论文的完成过程中，深受蔡老师的悉心指导与关怀。蔡老师学识渊博且治学严谨，具有深厚的学术功底，他严谨求实、锐意创新的学术精神使我受益匪浅。蔡老师不仅在学术上有很深的造诣，而且为人正直，宽厚仁和，我从他那里学到的不仅仅是学问，而且还有做人的道理。我为能够称为蔡老师的学生而深感荣幸。

感谢计算机学院院长康立山教授，在他所主持的演化计算讨论班中，我学到很多重要的知识，了解到演化计算的研究前沿和热点；同时，还深受康老师开放踏实和开拓创新的学风感化。

感谢陶家渠教授对我的指导与帮助，在我们的讨论班中，正是由于陶院长的指导才使我对 Kalman 滤波和组合导航知识有了较多的了解；同时，他在科学上严谨的作风和不知疲倦的忘我工作精神也深深地感化着我。

感谢计算机学院书记刘亚东教授和副书记李晖教授及计算机学院其他老师对我的帮助与支持。

感谢曾三友教授、Xin Yao 教授、Yiu-wing Leung 教授、Jun He 博士和周爱民博士等知名学者对我在科研中的帮助。

感谢我的师兄蒋良孝博士和颜雪松博士对我在生活和学习中的帮助。

感谢师兄蒋思伟、师姐郭嫚嫚以及同窗好友石杰楠、张烈超、陈昌敏、陆昕为、陈安升、韩茜、张红侠、詹炜、郑蔚、罗治情、王君、谷琼、彭锦国和师弟刘小波、陈光等对我在科研中的帮助，通过我们之间的相互讨论使我受益匪浅。

感谢湖北自然科学基金(2003ABA043)、湖北人文基地项目(2004B0011)和国家民用航天项目(C5220061318)的资助。

感谢我的母校中国地质大学（武汉），在这七年的学习生涯中，在校训“艰苦朴素、求真务实”的影响下，我逐渐成为了一个对社会有用的人。在此期间我学到了很有用的知识与技能以及懂得了做人的道理。

感谢我的父母对我的关爱与支持，是他们不懈地支持、鼓励和无怨无悔地付出才有了我的今天，使我能够安心顺利地完成学业。

最后，感谢所有关心和支持我的人，对他们表示最由衷的感谢和祝福！

参考文献

- [1] 靳蕃, 范俊波, 谭永东. 神经网络与神经计算机原理、应用. 成都: 西南交通大学出版社, 1993.
- [2] P.G.Lisboa (邢春颖, 阳 影, 等译). 现代神经网络应用. 北京: 电子工业出版社, 1996.
- [3] J. Von Neumann. Theory of self-reproducing automata, University of Illionis, Urbana, 1966.
- [4] 潘正君, 康立山, 陈毓屏. 演化计算. 北京: 清华大学出版社, 广西科学技术出版社, 2000.
- [5] R. E. Kalman. A New Approach to Linear Filtering and Prediction Theory. Trans. ASME. Journal of Basic Eng, 1960, 82D: 35 – 46.
- [6] 付梦印, 邓志红, 张继伟. Kalman 滤波理论及其在导航系统中的应用. 北京: 科学出版社, 2003.
- [7] R. E. Kalman, R. S. Bucy. New Results in Linear Filtering and Prediction Theory. Trans. ASME. Journal of Basic Eng, 1961, 83D: 95 – 108.
- [8] 邓自立. 自校正滤波理论及其应用—现代时间序列分析方法. 哈尔滨: 哈尔滨工业大学出版社, 2003.
- [9] 张炎华. 鲁棒滤波理论及捷联惯导系统研究. 上海交通大学出版社. 博士学位论文. 1996, 11.
- [10] G. Welch, and G. Bishop. An introduction to the kalman filter. Technical Report TR 95-041, University of North Carolina, Department of Computer Science, 1995.
- [11] 秦永元, 张洪钺, 汪叔华. 卡尔曼滤波与组合导航原理. 西安: 西北工业大学出版社, 2004.
- [12] 邓自立. 最优估计理论及其应用——建模、滤波、信息融合估计. 哈尔滨: 哈尔滨工业大学出版社, 2005.
- [13] T. Bäck, H.-P. Schwefel, An overview of evolutionary algorithms for parameter optimization. Evolutionary Computation, 1993, 1 (1): 1-23.
- [14] Y. W. Leung, Y. Wang. An Orthogonal Genetic Algorithm with Quantization for Global Numerical Optimization. IEEE Transactions on Evolutionary Computation, 2001, 5(1): 41-53.
- [15] Runarsson, T.P., Yao, X. Stochastic Ranking for Constrained Evolutionary Optimization. IEEE Transactions on Evolutionary Computation, 2000, 4: 284 – 294.
- [16] Deb, K., Pratap, A., Agarwal, S., Meyarivan, T.: A Fast and Elitist Multi-objective Genetic Algorithm: NSGA-II. IEEE Transactions on Evolutionary Computation. 2002, 6: 182 – 197.
- [17] 蔡之华, 彭锦国, 高 伟, 等. 一种改进的求解TSP问题的演化算法. 计算机学报, 2005,

- 28(5): 523 - 828.
- [18] Nidul Sinha, R. Chakrabarti, and P. K. Chattopadhyay. Evolutionary Programming Techniques for Economic Load Dispatch. *IEEE Transactions on Evolutionary Computation*, 2003, 7(1): 83 - 94.
- [19] C. S. Adjiman, I. P. Androulakis, and C. A. Floudas. Global Optimization of Mixed-Integer Nonlinear Problems. *PROCESS SYSTEMS ENGINEERING*, 2000, 46(9): 1769 - 1797.
- [20] R. Storn, K. Price, Differential evolution—A simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11: 341–359, 1997.
- [21] K. Price and R. Storn, Home Page of Differential Evolution, Available Online at: <http://www.ICSI.Berkeley.edu/~storn/code.html>, 2003.
- [22] Qingfu Zhang and Yiu-Wing Leung. An Orthogonal Genetic Algorithm for Multimedia Multicast Routing. *IEEE Transactions on Evolutionary Computation*, 1999, 3(1): 53 - 62.
- [23] 丁承民, 张传生, 刘贵忠. 正交试验遗传算法及其在函数优化中的应用. *系统工程与电子技术*, 1997, 10: 57-60.
- [24] 史奎凡, 董吉文, 李金屏, 等. 正交遗传算法. *电子学报*, 2002, 10: 1501-1504.
- [25] 曾三友, 魏巍, 康立山, 等. 基于正交设计的多目标演化算法[J]. *计算机学报*, 2005, 28(7): 1153-1162.
- [26] 方开泰, 马长兴. 正交与均匀实验设计. 北京: 科学出版社, 2001.
- [27] Coello Coello, C.A. Theoretical and Numerical Constraint Handling Techniques used with Evolutionary Algorithms: A Survey of the State of the Art. *Computer Methods in Applied Mechanics and Engineering*, 2002, 191: 1245–1287.
- [28] Smith, A.E., Coit, D.W. Constraint Handling Techniques—Penalty Functions. Oxford University Press and Institute of Physics Publishing, 1997.
- [29] Runarsson, T.P., Yao, X. Stochastic Ranking for Constrained Evolutionary Optimization. *IEEE Transactions on Evolutionary Computation*, 2000, 4: 284–294.
- [30] Deb, K. An Efficient Constraint Handling Method for Genetic Algorithms. *Computer Methods in Applied Mechanics and Engineering*, 2000, 186: 311–338.
- [31] E. Mezura-Montes, A. Coello Coello, and I. Tun-Morales. Simple Feasibility Rules and Differential Evolution for Constrained Optimization. *Proceedings of the 3rd Mexican International Conference on Artificial Intelligence*, 2004, 707 - 716.
- [32] Guo Tao, Kang Li-shan. A new Evolutionary Algorithm for Function Optimization. *Wuhan University Journal of Nature Sciences*, 1999, 4(4): 409-414.
- [33] Koziel, S., Michalewicz, Z. Evolutionary Algorithms, Homomorphous Mappings, and Constrained Parameter Optimization. *Evolutionary Computation*, 1999, 7: 19–44.
- [34] S. B. Hamida and M. Schoenauer, ASCHEA: New results using adaptive segregational constraint handling. In *Proc. Congress on Evolutionary Computation*, vol. 1, May 2002, 884 – 889.
- [35] J. T. Tsai, T. K. Liu and J. H. Chou. Hybrid Taguchi-Genetic Algorithm for Global Numerical

- Optimization. IEEE Transactions on Evolutionary Computation, 2004, 8(4): 365-377.
- [36] Sanyou Y.Zeng, Lishan S.Kang, Lixing X.Ding.: An Orthogonal Multiobjective Evolutionary Algorithm for Multi-objective Optimization Problems with Constraints. Evolutionary Computation, 2004, 12(1): 77 - 98
- [37] Wenyin Gong, Zhihua Cai, and Charles X. Ling, ODE: A Fast and Robust Differential Evolution Based on Orthogonal Design, AI 2006: Advances in Artificial Intelligence - 19th Australian Joint Conference on Artificial Intelligence, LNAI 4304, Springer-Verlag. 2006.12: 709-718.
- [38] 柏菁, 刘建业, 袁信. 模糊自适应卡尔曼滤波技术研究. 信息与控制, 2002 , 31 (3) : 193 - 197.
- [39] 徐田来, 游文虎, 崔平远. 基于模糊自适应卡尔曼滤波的INS/GPS 组合导航系统算法研究. 宇航学报, 2005, 26(5): 571-575.
- [40] 王子亮, 房建成, 全 伟. 基于遗传算法的多模型 Kalman 滤波算法及应用研究. 北京航空航天大学学报, 2004, 30(8): 748-752.
- [41] Magill D T. Optimal adaptive estimation of sampled stochastic processes. IEEE Trans AC, 1965 , 10 (5) : 434 - 439.
- [42] Zeke S. H. Chan, H. W. Ngan, A. B. Rad. A practical mutation operator and its application to the Kalman filter, Proceedings of International Conference on Power System Technology, 2000, 491 - 495.
- [43] Zeke S. H. Chan, H. W. Ngan, Y. F. Fung, *et al.* An Advanced Evolutionary Algorithm for Load Forecasting with the Kalman Filter, Proceedings of the 5th International Conference on Advances in Power System Control, Operation and Management. 2000, 134 - 138.
- [44] D. Loebis, R. Sutton, J. Chudley, *et al.* Adaptive tuning of a Kalman filter via fuzzy logic for an intelligent AUV navigation system. Control Engineering Practice, 2004, 12: 1531-1539.
- [45] M. A. Hassanain, M. M. Reda Taha, A. Noureldin, *et al.* Automization Of An INS/GPS Integrated System Using Genetic Optimization. Fifth International Symposium on Intelligent Automation and Control, 2004.
- [46] 郭 涛, 康立山, 李 艳. 一种求解不等式约束下函数优化问题的新算法. 武汉大学学报(自然科学版), 1999, 45(5): 771 - 775.
- [47] 何 渝. 计算机常用数值算法与程序(C++版). 北京: 人民邮电出版社, 2003.
- [48] X. Yao, Y. Liu, G. Lin. Evolutionary Programming Made Faster. IEEE Transactions on Evolutionary Computation, 1999, 3(2): 82 - 102.